



第二部分：统计学基本概念

何志坚 教授/博导

华南理工大学数学学院

☎020-87111271

✉hezhijian@scut.edu.cn

🌐www.hezhijian.com.cn

2025 年 2 月 23 日



目录

1 总体与样本

2 分布族

3 统计量

总体

总体

我们把研究对象的全体（包括有形的和潜在的）称作总体，其中每个成员称为个体。常用随机变量 X 来刻画一个总体（或者总体的特征值）。

例 1

- 网上购物居民占全市居民的比例
- 过去一年内网购居民的购物次数
- 某品牌灯泡的寿命

注：总体 X 的分布函数 $F(x)$ 未知或者部分未知，统计学的核心任务就是要对总体进行观测，并对所得数据推断总体的分布信息。

样本

研究总体可分为普查和抽样这两种方法。

普查（全数检查）

- 对总体中的每个个体进行观察，如我国每十年一次的人口普查
- 缺点：费用高、时间长、不适合破坏性试验

抽样

- 从总体中抽取若干个体进行观察，用所获得数据对总体进行统计推断
- 优点：费用低、时间短
- 抽取的部分组成的集合 $X_{1:n} = (X_1, \dots, X_n)$ 称为样本， X_i 称为样品
- 样品个数 n 称为样本量或者样本容量

人口普查	第七次人口普查数据	第七次人口普查主要数据
	第六次人口普查数据	第五次人口普查数据
经济普查	第四次经济普查	第三次经济普查
	第二次经济普查	第一次经济普查
农业普查	第三次农业普查	第二次农业普查
	第一次农业普查	
R&D资源清查	第二次R&D资源清查	
工业普查	第三次工业普查	
三产普查	第一次三产普查	
基本单位普查	第二次基本单位普查	第一次基本单位普查

来源国家统计局: <https://www.stats.gov.cn/sj/pcsj/>

简单随机抽样

简单随机抽样满足以下两个特征：

- 随机性：每个个体都有相同的机会选中（有放回随机抽取/独立重复观测），即 X_i 与 X 同分布
- 独立性：每个样本的选取是独立的这种方式得到的样本称为简单随机样本（简称样本）
- $X_1, \dots, X_n$ 独立同分布 (independent and identically distributed, iid)
- 本课程所研究的主要为简单随机样本

样本具有两重性

- 抽取之前无法预知它们的数值，故 $X_{1:n} = (X_1, \dots, X_n)$ 为随机变量；统计分析基于随机变量
- 抽取后样本为具体的数，用小写字母 $x_{1:n} = (x_1, \dots, x_n)$ 表示观测值，称为样本观测值；统计推断结论基于样本观测值（数据）



目录

1 总体与样本

2 分布族

3 统计量

概率分布族

模型假定：总体 X 分布 $F(x)$ 属于某个分布族 $\mathcal{F}$. 分为以下三类：

- 参数族： $\mathcal{F}$ 中的分布的一般数学形式已知，但包含若干未知参数。即 $\mathcal{F} := \{F_\theta | \theta \in \Theta\}$, 其中 $\theta = (\theta_1, \dots, \theta_m)$, $\Theta \subset \mathbb{R}^m$ 称为参数空间, m 为模型参数的维数。 $m = 1$ 为单参数统计问题, $m > 1$ 为多参数统计问题。
- 非参数族：当 $\mathcal{F}$ 中的分布不能通过有限个未知参数来刻画。
- 半参数族： $\mathcal{F}$ 中的分布有一部分可以用参数刻画，一部分则不可以。

常见分布函数

- 累积分布函数 (cumulative distribution function, CDF): $F_\theta(x) = P(X \leq x)$
- 概率质量函数 (probability mass function, PMF): $f_\theta(x) = P(X = x)$
- 概率密度函数 (probability density function, PDF): $f_\theta(x) = F'_\theta(x)$
- 一般地，我们记 $X \sim F_\theta(x)$ 或者 $X \sim f_\theta(x)$ (离散型 PMF, 连续型 PDF)

常用的参数族

离散型

- 二项分布族 $\{B(n, p) | 0 < p < 1\}$
- 几何分布族 $\{Ge(p) | 0 < p < 1\}$
- 泊松分布族 $\{Pois(\lambda) | \lambda > 0\}$

连续型

- 正态分布族 $\{N(\mu, \sigma^2) | -\infty < \mu < \infty, \sigma > 0\}$
- 均匀分布族 $\{U(a, b) | -\infty < a < b < \infty\}$
- 指数分布族 $\{Exp(\lambda) | \lambda > 0\}$
- 伽玛分布族 $\{Gamma(\alpha, \lambda) | \alpha > 0, \lambda > 0\}$
- 贝塔分布族 $\{Gamma(\alpha_1, \alpha_2) | \alpha_1 > 0, \alpha_2 > 0\}$

伽玛分布

回忆伽玛函数：

$$\Gamma(\alpha) = \int_0^{\infty} x^{\alpha-1} e^{-x} dx, \alpha > 0$$

■ $\Gamma(1) = 1, \Gamma(1/2) = \sqrt{\pi}$

■ $\Gamma(\alpha + 1) = \alpha\Gamma(\alpha)$

■ $\Gamma(n) = (n-1)!, n \in \mathbb{Z}^+$

(1) 先定义单参数伽玛分布 $\text{Gamma}(\alpha)$, $\alpha > 0$, 其 PDF 为：


$$f(x; \alpha, 1) = \frac{1}{\Gamma(\alpha)} x^{\alpha-1} e^{-x} 1\{x > 0\}$$

(2) 再定义两参数伽玛分布 $\text{Gamma}(\alpha, \lambda) = \frac{1}{\lambda} \text{Gamma}(\alpha)$, $\alpha > 0, \lambda > 0$, 其 PDF 为：

$$f(x; \alpha, \lambda) = \lambda f(\lambda x; \alpha, 1) = \frac{\lambda^\alpha}{\Gamma(\alpha)} x^{\alpha-1} e^{-\lambda x} 1\{x > 0\}$$

伽玛分布 (续)

- α : 形状参数
- λ : 速率参数
- $1/\lambda$: 尺度参数
- 特例: $\text{Exp}(\lambda) = \text{Gamma}(1, \lambda)$



伽玛分布性质

- 性质 1 (可加性): 设 $X_1 \sim \text{Gamma}(\alpha_1, \lambda)$, $X_2 \sim \text{Gamma}(\alpha_2, \lambda)$ 。如果 X_1 与 X_2 独立, 则

$$X_1 + X_2 \sim \text{Gamma}(\alpha_1 + \alpha_2, \lambda).$$

- 性质 2 (可乘性): 设 $X \sim \text{Gamma}(\alpha, \lambda)$, 则 $kX \sim \text{Gamma}(\alpha, \lambda/k)$, 其中 $k > 0$ 。

- 提示: $\text{Gamma}(\alpha, \lambda)$ 分布的特征函数为

$$\phi(t) = \mathbb{E}[e^{itX}] = \left(1 - \frac{it}{\lambda}\right)^{-\alpha}.$$

贝塔分布

■ 回忆贝塔函数：


$$B(\alpha_1, \alpha_2) = \int_0^1 x^{\alpha_1-1} (1-x)^{\alpha_2-1} dx = \frac{\Gamma(\alpha_1)\Gamma(\alpha_2)}{\Gamma(\alpha_1 + \alpha_2)}, \quad \alpha_1, \alpha_2 > 0.$$

■ 贝塔分布记为 $\text{Beta}(\alpha_1, \alpha_2)$ ，其中形状参数 $\alpha_1 > 0, \alpha_2 > 0$. 其 PDF 为：

$$f(x; \alpha_1, \alpha_2) = \frac{\Gamma(\alpha_1 + \alpha_2)}{\Gamma(\alpha_1)\Gamma(\alpha_2)} x^{\alpha_1-1} (1-x)^{\alpha_2-1} 1\{0 < x < 1\}.$$

■ 特例：当 $\alpha = \beta = 1$ 时， $\text{Beta}(1, 1) = \mathbb{U}(0, 1)$

贝塔分布密度



伽玛和贝塔分布的联系

定理 1

如果 $X_1 \sim \text{Gamma}(\alpha_1, \lambda)$, $X_2 \sim \text{Gamma}(\alpha_2, \lambda)$, 且 X_1, X_2 独立, 则

- $Y_1 = X_1 + X_2 \sim \text{Gamma}(\alpha_1 + \alpha_2, \lambda)$
- $Y_2 = \frac{X_1}{X_1 + X_2} \sim \text{Beta}(\alpha_1, \alpha_2)$
- Y_1 与 Y_2 独立, 记为 $Y_1 \perp\!\!\!\perp Y_2$ 。

习题 1

如果 $X_i \stackrel{\text{iid}}{\sim} \text{Exp}(\lambda)$, 求以下分布:

- $S_n = \sum_{i=1}^n X_i,$
- $\bar{X} = \frac{1}{n} \sum_{i=1}^n X_i.$

指数型分布族

定义 1 (指数型分布族)

设分布族 $\mathcal{F} = \{f_\theta(x) | \theta \in \Theta\}$, 其中 $f_\theta(x)$ 为概率密度函数或者概率质量函数. 分布族 $\mathcal{F}$ 称为指数型分布族当且仅当 $f_\theta(x)$ 可表示为如下形式:

$$f_\theta(x) = c(\theta) \exp \left\{ \sum_{j=1}^k c_j(\theta) T_j(x) \right\} h(x), \quad (1)$$

其中, k 为正整数, 称为该指数分布族的 “维数”, $c(\theta) > 0$, $c_j(\theta)$ 为定义在参数空间 Θ 上的实值函数, $h(x) \geq 0$.

令 $\eta_j = c_j(\theta)$, $\eta = \eta(\theta) = (\eta_1, \dots, \eta_k)$, 则(1)可以变成关于新参数 η 的函数

$$f_\eta(x) = \tilde{c}(\eta) \exp \left\{ \sum_{j=1}^k \eta_j T_j(x) \right\} h(x), \quad (2)$$

其中 $1/\tilde{c}(\eta) = \int \exp \left\{ \sum_{j=1}^k \eta_j T_j(x) \right\} h(x) dx$. 称(2)为指数型分布族(1)的规范化形式, η_i 为自然参数, $\mathcal{N} = \{\eta(\theta) | \theta \in \Theta\} \subset \mathbb{R}^k$ 为自然参数空间. 如果 $\mathcal{N}$ 存在 $\mathbb{R}^k$ 中的一个内点, 则称该指数型分布族是满秩的.

一些例子

- 正态分布族 $\{N(\mu, \sigma^2) | \mu \in \mathbb{R}, \sigma^2 > 0\}$

$$f(x; \mu, \sigma^2) = \frac{1}{\sqrt{2\pi}\sigma} e^{-\frac{(x-\mu)^2}{2\sigma^2}}$$

- 伽玛分布族 $\{\text{Gamma}(\alpha, \lambda) | \alpha > 0, \lambda > 0\}$

$$f(x; \alpha, \lambda) = \frac{\lambda^\alpha}{\Gamma(\alpha)} x^{\alpha-1} e^{-\lambda x} 1\{x > 0\}$$

- 伯努利分布族 $\{B(1, p) | p > 0\}$

$$f(x; p) = p^x (1-p)^{1-x}, \quad x \in \{0, 1\}$$

- 泊松分布族 $\{\text{Pois}(\lambda) | \lambda > 0\}$

$$f(x; \lambda) = \frac{\lambda^x e^{-\lambda}}{x!}, \quad x = 0, 1, \dots$$

一些反例

- 均匀分布族 $\{\mathbb{U}[a, b] | a < b\}$
- 威布尔 (Weibull) 分布族 $\{\text{Wei}(\alpha, \lambda) | \alpha > 0, \lambda > 0\}$

$$f(x; \alpha, \lambda) = \alpha \lambda^\alpha x^{\alpha-1} \exp \{-(\lambda x)^\alpha\} 1\{x > 0\}$$

指数型简单样本的联合分布属于指数型分布族

命题 2

如果 $X_1, \dots, X_n$ 是来自指数型分布族中某分布的样本, 则该样本的联合分布还是指数型分布.

证明.

不难计算, 样本的联合密度函数为

$$f_{\theta}(x_1, \dots, x_n) = \prod_{i=1}^n f_{\theta}(x_i) = c(\theta)^n \exp \left\{ \sum_{j=1}^k c_j(\theta) \sum_{i=1}^n T_j(x_i) \right\} \prod_{i=1}^n h(x_i).$$

对比形式(1)发现, 样本的联合分布还是指数型分布. □

思考: 联合分布与边际分布的指数型分布有哪些相同点?



目录

1 总体与样本

2 分布族

3 统计量

统计量

样本是总体的反映, 但样本所含信息不能直接用于解决我们所要研究的问题, 而需要把样本所含的信息进行数学上的加工使其浓缩起来, 从而解决我们的问题. 为此, 统计推断需要构造 (一个或者多个) 合适的依赖于样本的函数, 称之为统计量.

定义 2

设 $(X_1, \dots, X_n)$ 是总体 X 的样本, ℓ 为正整数. 若样本函数

$$T = T(X_1, \dots, X_n) : \mathbb{R}^n \rightarrow \mathbb{R}^\ell$$

是不含有任何未知参数的 (可测) 函数, 则称 T 为统计量. 统计量的分布称为抽样分布.

- 用于估计未知参数的统计量称为点估计量, 或者简称估计量
- 用于检验的统计量称为检验统计量
- 统计量是随机变量 (向量)

常见的统计量

- 样本均值: $\bar{X} = \bar{X}_n = \frac{1}{n} \sum_{i=1}^n X_i$
- 样本方差: $S_n^2 = \frac{1}{n} \sum_{i=1}^n (X_i - \bar{X})^2$
- 修正样本方差:

$$S_n^{*2} = \frac{1}{n-1} \sum_{i=1}^n (X_i - \bar{X})^2 = \frac{n}{n-1} S_n^2$$


- 样本标准差: $S_n = \sqrt{S_n^2}$
- 样本 k 阶原点矩: $M_k = \frac{1}{n} \sum_{i=1}^n X_i^k$
- 样本 k 阶中心矩: $\tilde{M}_k = \frac{1}{n} \sum_{i=1}^n (X_i - \bar{X})^k$
- 顺序统计量: $X_{(1)} \leq X_{(2)} \leq \cdots \leq X_{(n)}$, 其中 $X_{(1)} = \min\{X_1, \dots, X_n\}$, $X_{(n)} = \max\{X_1, \dots, X_n\}$, $X_{(k)}$ 为 $X_1, \dots, X_n$ 的递增排序的第 k 位.
- 样本极差: $X_{(n)} - X_{(1)}$.
- 样本分位数: $X_{(\lceil \alpha n \rceil)}$, 其中 $\alpha \in (0, 1)$

箱线图



deepseek

“给出一段 R 代码画出男女身高数据的箱线图”



- $MAX = X_{(n)}$, $MIN = X_{(1)}$, Q_i 是 $i/4$ 样本分位数
- 异常值: $> Q3 + 1.5(Q3 - Q1)$ 或者 $< Q1 - 1.5(Q3 - Q1)$

充分统计量

统计量各式各样, 有些并不能反映有用的信息. 但有一类统计量比较特殊, 称为充分统计量, 它不仅能够简化数据且不损失样本信息.

定义 3

设有一个分布族 $\mathcal{F}$, $X_1, \dots, X_n$ 是从某分布 $F \in \mathcal{F}$ 中抽取的一个样本.
 $T = T(X_1, \dots, X_n)$ 是一个统计量.

- 样本的条件分布 $(X_1, \dots, X_n) | T$ 与总体分布 F 无关, 则称 T 为此分布族 $\mathcal{F}$ 的充分统计量.
- 如果 $\mathcal{F} = \{F_\theta | \theta \in \Theta\}$ 是参数分布族, 样本的条件分布 $(X_1, \dots, X_n) | T$ 与参数 θ 无关, 则称 T 为参数 θ 的充分统计量.

由充分统计量恢复样本信息

- 可观测的充分统计量 $T \sim f_T(t)$, 设其观测值为 $T = t$
- 计算机仿真样本: $\tilde{X}_{1:n} \sim f(x_{1:n} | T = t)$
- 则可得到同分布的“山寨样本” $\tilde{X}_{1:n} \stackrel{d}{=} X_{1:n}$

一个简单的例子

习题 2

总体 $X_i \stackrel{\text{iid}}{\sim} B(1, p), 0 < p < 1, i = 1, \dots, n > 2$. 判断 $T_1 = \sum_{i=1}^n X_i$ 和 $T_2 = X_1 + X_2$ 是否是充分统计量?

因子分解定理

前面的例子是通过充分统计量的定义判断, 要求条件分布, 比较繁琐. 下面介绍因子分解定理, 由 J. Neyman 和 P. R. Halmos 在 20 世纪 40 年代提出, 能够很方便地判断和求解充分统计量.

定理 3 (因子分解定理)

设样本 $(X_1, \dots, X_n)$ 的联合概率质量函数或者密度函数为 $f_\theta(x_1, \dots, x_n)$, 其中 $\theta \in \Theta$. 则统计量 T 是充分的当且仅当存在两个函数满足

- (1) $h(x_1, \dots, x_n)$ 非负;
- (2) 在统计量 T 取值空间上的函数 $g_\theta(t)$, 使得

$$f_\theta(x_1, \dots, x_n) = g_\theta(T(x_1, \dots, x_n))h(x_1, \dots, x_n), \quad \forall \theta \in \Theta. \quad (3)$$

因子分解定理的应用

例 2 (正态分布族)

假设 $X_i \stackrel{\text{iid}}{\sim} N(\mu, \sigma^2), \mu \in \mathbb{R}, \sigma > 0$ 。求以下三种情形参数的充分统计量。

- $\theta = (\mu, \sigma^2)$;
- $\theta = \mu$, 其中 σ^2 已知;
- $\theta = \sigma^2$, 其中 μ 已知。

例 3 (指数型分布族)

假设 $X_i \stackrel{\text{iid}}{\sim} f_{\theta}(x) = c(\theta) \exp \left\{ \sum_{j=1}^k c_j(\theta) T_j(x) \right\} h(x), \theta \in \Theta$ 。求参数 θ 的充分统计量。

充分统计量的唯一性

显然, 充分统计量不是唯一的, 有无穷多个, 其中一个平凡的充分统计量为完全样本 $X_{1:n}$. 下面定理刻画它们之间的内在联系.

定理 4

如果 T 是 n_1 维充分统计量, S 是 n_2 维统计量且 $T = \psi(S)$, 其中

$$\psi: \mathbb{R}^{n_2} \rightarrow \mathbb{R}^{n_1}$$

是可测函数, 则 S 也是充分的.

习题 3

总体分布为 $N(\mu, \sigma^2)$, 以下哪些统计量为参数 (μ, σ^2) 的充分统计量?

- $T_1 = (\bar{X}, S_n)$
- $T_2 = (\bar{X}, S_n^2)$
- $T_3 = (\bar{X}, S_n^*)$
- $T_7 = (\sum_{i=1}^n X_i, \sum_{i=1}^n |X_i|, \sum_{i=1}^n X_i^2).$
- $T_4 = (\bar{X}, S_n^{*2})$
- $T_5 = (\sum_{i=1}^n X_i, \sum_{i=1}^n X_i^2)$
- $T_6 = (\sum_{i=1}^n X_i, \sum_{i=1}^n |X_i|)$



选学内容

自编讲义第 1.6 节及其参考文献：

- 最小充分统计量
- 完备统计量