



第三部分：点估计方法

何志坚 教授/博导

华南理工大学数学学院

☎020-87111271

✉hezhijian@scut.edu.cn

🌐www.hezhijian.com.cn

2025 年 3 月 7 日



目录

1 参数估计问题

2 矩估计方法

3 最大似然估计方法

参数估计问题

- 模型假设: $X_{1:n} \sim F \in \mathcal{F}$
- 参数估计问题: 估计总体的未知特征 $g(F) \in \mathbb{R}^m$, 如期望、方差等
- 特别地, 对于参数分布族 $\mathcal{F} = \{F_\theta | \theta \in \Theta\}$, 待估问题可表示为 $g(F) = g(\theta)$
- 参数估计的方式: 点估计和区间估计

参数可识别性

假设总体分布为 $F_\theta, \theta \in \Theta$. 如果不存在 $\theta_1 \neq \theta_2$ 使得 $F_{\theta_1} = F_{\theta_2}$, 则称 θ 是可识别的. 否则称 θ 不可识别.

例 1

设 $X_i \stackrel{\text{iid}}{\sim} N(\mu_1 + \mu_2, \sigma^2)$, 试判断参数 $\theta = (\mu_1, \mu_2, \sigma^2)$ 是否可识别? 如果不可识别该如何处理?

点估计

定义 1

假设样本 $X_{1:n} \sim F_\theta, \theta \in \Theta$, $g(\theta)$ 为参数 θ 的实值函数。用统计量 $T(X_{1:n})$ 作为 $g(\theta)$ 估计, 称为**点估计**, 此时 $T(X_{1:n})$ 称为 $g(\theta)$ 的**(点)估计量**, $T(x_{1:n})$ 称为**估计值**。如果 $g(\theta) = \theta$, 常用记号 $\hat{\theta}$ 表示估计量。

例 2 (估计灯泡的平均寿命)

某工厂生产灯泡, 假设寿命服从正态分布 $N(\mu, \sigma^2)$ 。质检部门随机抽取 8 个灯泡测试寿命 (小时): 1200, 1250, 1180, 1220, 1300, 1150, 1230, 1270。

例 3 (估计呼叫中心每小时来电次数)

某呼叫中心假设每小时接到的电话数服从泊松分布 $\text{Pois}(\lambda)$ 。记录 5 小时内的来电次数为 5, 3, 7, 4, 6。

例 4 (估计产品合格率)

某生产线生产一批产品, 质检员随机抽取 200 件, 发现 192 件合格。



目录

1 参数估计问题

2 矩估计方法

3 最大似然估计方法

矩估计方法（矩法）

- 模型设定：总体 $X \sim F_\theta(x)$, 简单随机样本 $X_i \stackrel{\text{iid}}{\sim} F_\theta(x)$
- 模型参数： $\theta = (\theta_1, \dots, \theta_m)$
- 矩估计 (the method of moments, MoM) 的想法来源于大数定理. 如果总体 X 存在 k 阶矩, 对任意 $\epsilon > 0$,

$$\lim_{n \rightarrow \infty} \mathbb{P} \left(\left| \frac{1}{n} \sum_{i=1}^n X_i^k - \mathbb{E}[X^k] \right| \geq \epsilon \right) = 0.$$

- 矩法估计核心思想是用样本的矩近似总体的矩
- 总体 k 阶矩记为 $\mu_k = \mathbb{E}[X^k]$
- 样本 k 阶矩记为 $\hat{\mu}_k = \frac{1}{n} \sum_{i=1}^n X_i^k$, 作为 μ_k 的矩估计
- 对于一般的待估参数 $g(\theta)$, 如果它可以用总体的矩表示, 不妨记为

$$g(\theta) = h(\mu_1, \dots, \mu_m),$$

则矩估计定义为

$$T(X_{1:n}) = h(\hat{\mu}_1, \dots, \hat{\mu}_m).$$

求解步骤

- 先求出 $\theta = (\theta_1, \dots, \theta_m)$ 的矩估计 $\hat{\theta} = (\hat{\theta}_1, \dots, \hat{\theta}_m)$
- 然后代入得到 $g(\theta)$ 的矩估计 $g(\hat{\theta})$

模型参数的矩估计求解过程

- 求总体 k 阶矩: $\mu_k = \mathbb{E}[X^k] = Q_k(\theta_1, \dots, \theta_m)$, $k = 1, \dots, m$
- 用总体矩表示参数: $\theta_k = L_k(\mu_1, \dots, \mu_m)$
- 用样本矩 $\hat{\mu}_k$ 替代总体矩 μ_k 得到矩估计 $\hat{\theta}_k = L_k(\hat{\mu}_1, \dots, \hat{\mu}_m)$.

例子

例 5

求总体 X 的期望 $\mu = \mathbb{E}[X]$ 与方差 $\sigma^2 = \text{Var}[X]$ 的矩估计量.

例 6

设总体 $X \sim U[a, b]$, 求 a, b 的矩估计量.

例 7

设总体 X 的分布密度为

$$f(x) = \frac{\theta}{2} e^{-\theta|x|}, \quad x \in \mathbb{R}, \theta > 0.$$

求 θ 的矩估计.

小结

- 核心思想：矩的替代，这里包括原点矩与中心矩
- 适用范围：简单随机样本（IID 样本）
- 唯一性：矩法不唯一，应尽量选择低阶矩表示
- 优势 1：对于一些问题，矩法不依赖统计模型
- 优势 2：矩估计容易并行计算，提高计算速度
- 缺点 1：对于复杂的问题，需要数值求根方法才能得到矩估计值
- 缺点 2：矩估计不一定落在参数取值范围，即 $\hat{\theta} \notin \Theta$



目录

1 参数估计问题

2 矩估计方法

3 最大似然估计方法

一个简单案例

- 最大似然估计法 (maximum likelihood estimation, MLE) 最早由高斯提出, 后来被 R. A. Fisher 完善并取名
- MLE 是广泛应用的点估计方法. 它是建立在最大似然原理基础上的一个统计方法.
- 最大似然原理是指“最先出现的是最有可能的”

例 8

设有一个箱子有许多黑球和白球, 已知它们的比例是 $1:3$ 但不知道黑球多还是白球多. 今从该箱子中有放回随机抽取 n 个球, 如何根据抽样数据判断抽到黑球的概率是 $1/4$ 还是 $3/4$?

- 情形一: $n = 1$, 抽到黑球
- 情形二: $n = 3$, 依次抽到“黑球”、“白球”、“白球”

问题转换

- 样本 $X_i = 1\{\text{抽到黑球}\} \stackrel{\text{iid}}{\sim} B(1, \theta)$, $\theta \in \{1/4, 3/4\}$, 求 $\theta = ?$
- 矩估计 $\hat{\theta}_{\text{MoM}} = \bar{X}$
- 对于情形二, $\hat{\theta}_{\text{MoM}} = 1/3 \notin \{1/4, 3/4\}$
- 计算看到样本 $X_{1:n} = x_{1:n}$ 的概率,

$$L(\theta, x_{1:n}) = f_{\theta}(x_{1:n}) = \mathbb{P}_{\theta}(X_{1:n} = x_{1:n}) = \theta^{\sum_{i=1}^n x_i} (1 - \theta)^{n - \sum_{i=1}^n x_i}$$

$s = \sum_{i=1}^n x_i$	0	1	2	3
$\theta = 1/4$	$\frac{27}{64}$	$\frac{27}{64}$	$\frac{9}{64}$	$\frac{1}{64}$
$\theta = 3/4$	$\frac{1}{64}$	$\frac{9}{64}$	$\frac{27}{64}$	$\frac{27}{64}$

- 对于情形二, $\hat{\theta}_{\text{MLE}} = 1/4 \in \{1/4, 3/4\}$
- 更一般地, $\hat{\theta}_{\text{MLE}} = \hat{\theta}_{\text{MLE}}(x_{1:n}) = \arg \max_{\theta \in \Theta} L(\theta, x_{1:n})$

MLE 的定义

定义 2 (MLE)

假设 $X_{1:n} \sim f_\theta(x_{1:n})$, $\theta \in \Theta$, 其中 $f_\theta(\cdot)$ 表示 *PDF* 或者 *PMF*. 当 $x_{1:n}$ 给定时, 把 $f_\theta(x_{1:n})$ 看成 $\theta \in \Theta$ 的函数, 称为似然函数 (*likelihood function*) 并记为

$$L(\theta) = L(\theta, x_{1:n}) = f_\theta(x_{1:n}), \theta \in \Theta.$$

称 $\ell(\theta, x_{1:n}) = \ln L(\theta, x_{1:n})$ 为对数似然函数。记

$$\hat{\theta}_{\text{MLE}}(x_{1:n}) = \arg \max_{\theta \in \Theta} L(\theta, x_{1:n}) = \arg \max_{\theta \in \Theta} \ell(\theta, x_{1:n}).$$

则称 $\hat{\theta}_{\text{MLE}}(X_{1:n})$ 为最大似然估计量 (*MLE*), 简记为 $\hat{\theta}_{\text{MLE}}$. 若待估参数为 $g(\theta)$, 则 *MLE* 为 $g(\hat{\theta}_{\text{MLE}})$.

MLE 的求解

- 对于单参数情形, 假设 $L(\theta)$ 或者 $\ell(\theta)$ 光滑。求极值点, 得到对数似然方程: $\ell'(\theta) = 0$
- 对于多参数情形, $\theta = (\theta_1, \dots, \theta_m) \in \mathbb{R}^m$, 对数似然方程为:

$$\nabla \ell(\theta) = \left(\frac{\partial \ell(\theta)}{\partial \theta_1}, \dots, \frac{\partial \ell(\theta)}{\partial \theta_m} \right)^\top = 0$$

- 判断极大值点:

$$H(\theta) = \left(\frac{\partial^2 \ell(\theta)}{\partial \theta_i \partial \theta_j} \right)_{m \times m} \text{ 负定}$$

- 对于 IID 的样本,

$$\ell(\theta) = \ln L(\theta) = \ln \left(\prod_{i=1}^n f_{\theta}(x_i) \right) = \sum_{i=1}^n \ln f_{\theta}(x_i)$$

$$\frac{\partial \ell(\theta)}{\partial \theta_k} = \sum_{i=1}^n \frac{\partial f_{\theta}(x_i)}{\partial \theta_k} \bigg/ f_{\theta}(x_i), \quad k = 1, \dots, m$$

例子

例 9

设样本 $X_i \stackrel{\text{iid}}{\sim} N(\mu, \sigma^2)$, $i = 1, \dots, n$,

- 求参数 μ, σ^2 的 MLE;
- 已知 σ^2 , 求 μ 的 MLE;
- 已知 μ , 求 σ^2 的 MLE.
- 已知 $\mu \geq 1$, 求参数 μ, σ^2 的 MLE.

例 10

设样本 $X_i \stackrel{\text{iid}}{\sim} U[a, b]$, $i = 1, \dots, n$, 求参数 a, b 的最大似然估计.

指数型分布族

回忆指数型分布族的规范化形式:

$$f_{\eta}(x) = \tilde{c}(\eta) \exp \left\{ \sum_{j=1}^k \eta_j T_j(x) \right\} h(x), \quad \eta \in \mathcal{N}$$

指数型分布族的似然方程

假设 $X_i \stackrel{\text{iid}}{\sim} f_{\eta}(x)$, $i = 1, \dots, n$ 。则对数似然方程为:

$$\frac{n}{\tilde{c}(\eta)} \frac{\partial \tilde{c}(\eta)}{\partial \eta_j} = \tilde{T}_j(x_{1:n}) = \sum_{i=1}^n T_j(x_i), \quad j = 1, \dots, k.$$

MLE 与充分统计量的联系

- 设 $T(X_{1:n})$ 为充分统计量，则由因子分解定理有

$$f_{\theta}(x_{1:n}) = g_{\theta}(T(x_{1:n}))h(x_{1:n})$$

- MLE 为

$$\hat{\theta}_{\text{MLE}} = \arg \max_{\theta \in \Theta} g_{\theta}(T(x_{1:n}))h(x_{1:n}) = \arg \max_{\theta \in \Theta} g_{\theta}(T(x_{1:n})) = S(T(x_{1:n}))$$

- 结论：MLE 为充分统计量 $T(X_{1:n})$ 的函数


小结

- MLE 落在参数空间
- MLE 不唯一
- MLE 不一定存在，此时可用极大值点代替（极大似然估计）
- MLE 的适用范围更广，不局限 IID 样本
- 似然方程可能要用数值求解

数值求解 MLE

- Newton-Raphson 算法: $\theta^{(t+1)} = \theta^{(t)} - H(\theta^{(t)})^{-1} \nabla \ell(\theta^{(t)})$
- 梯度上升算法: $\theta^{(t+1)} = \theta^{(t)} + \eta_t \nabla \ell(\theta^{(t)})$, $\eta_t > 0$
- EM (Expectation-Maximization) 算法: 适用潜变量模型, 如:

$$f_{\theta}(x_{1:n}) = \int f_{\theta}(x_{1:n}, y_{1:n}) dy_{1:n} = \int f_{\theta}(x_{1:n} | y_{1:n}) \tilde{f}_{\theta}(y_{1:n}) dy_{1:n}$$



Dempster, A.P., Laird, N.M. and Rubin, D.B. (1977), [Maximum Likelihood from Incomplete Data Via the EM Algorithm](#). Journal of the Royal Statistical Society: Series B (Methodological), 39: 1-22.

案例一：车流量数据

例 11

以下数据统计了某个路口一小时内观察到出租车的数量。假设这些数据遵循几何分布：

$$p_X(k; p) = (1 - p)^{k-1} p, k = 1, 2, \dots$$

请估计该路口一小时的平均车流量。

车辆数/小时	频数
1	678
2	227
3	56
4	28
5	8
6+	14
总数	1011

求解过程

- 设 $X_i \stackrel{\text{iid}}{\sim} \text{Ge}(p)$ 表示第 i 个小时观测到的车辆数, $i = 1, \dots, n = 1011$
- 设 N_i 表示 n 次观测中看到 i 辆车的次数, $i = 1, \dots, 5$, $N_6 = n - \sum_{i=1}^5 N_i$
- 则有 $(N_1, \dots, N_6) \sim \text{multinomial}(n; p_1, p_2, \dots, p_6)$, 其中

$$p_i = (1 - p)^{i-1} p, \quad i = 1, \dots, 5, \quad p_6 = 1 - \sum_{i=1}^5 p_i = (1 - p)^5$$

- 似然函数:

$$L(p) = P(N_1 = n_1, \dots, N_6 = n_6) = \frac{n!}{n_1! \dots n_6!} p_1^{n_1} \dots p_6^{n_6}.$$

$$\begin{aligned} \ell(p) &= \ln L(p) = \sum_{i=1}^6 n_i \ln p_i + \text{const} \\ &= \left(\sum_{i=1}^5 n_i \right) \ln p + \left[\sum_{i=2}^6 (i-1) n_i \right] \ln(1-p) + \text{const}. \end{aligned}$$

求解过程 (续)

■ 似然方程:

$$\ell'(p) = \left(\sum_{i=1}^5 n_i \right) / p - \left[\sum_{i=2}^6 (i-1)n_i \right] / (1-p) = 0$$

■ MLE 为:


$$\hat{p}_{\text{MLE}} = \frac{N_1 + N_2 + \cdots + N_5}{N_1 + 2N_2 + 3N_3 + 4N_4 + 5N_5 + 5N_6}.$$

■ 对比 X_i 可观测时的 MLE 估计:

$$\tilde{p}_{\text{MLE}} = \frac{1}{\bar{X}} = \frac{N_1 + N_2 + \cdots + N_5 + N_6}{N_1 + 2N_2 + 3N_3 + 4N_4 + 5N_5 + 6N_6}.$$


对数似然函数的图像

代入数据得到 $\hat{p}_{MLE} = 0.6642576$ ，平均车流量为： $1/\hat{p}_{MLE} = 1.50544$



案例二：删失数据

- 假设 $Y_i \stackrel{iid}{\sim} f_{\theta}(y)$, 但如果 $Y_i > t_i$ 则观测不到 Y_i 只知道 $Y_i > t_i$.



- 令 $\delta_i = 1$ 如果 Y_i 被观测 (死亡), 否则 $\delta_i = 0$ (生存) .
- 似然函数为

$$L(\theta) = \prod_{i=1}^n f_{\theta}(y_i)^{\delta_i} S_{\theta}(t_i)^{1-\delta_i},$$

其中 $F_{\theta}(t)$ 是 Y_i 的 CDF, $S_{\theta}(t) = 1 - F_{\theta}(t)$ 为生存函数.

指数分布

- 现设 $Y_i \stackrel{iid}{\sim} \text{Exp}(\lambda)$. 则有

$$\begin{aligned} L(\lambda) &= \prod_{i=1}^n (\lambda \exp(-\lambda y_i))^{\delta_i} (\exp(-\lambda t_i))^{1-\delta_i} \\ &= \lambda^{n_1} \exp\left[-\sum_{i=1}^n (\delta_i y_i + (1 - \delta_i) t_i) \lambda\right] \end{aligned}$$

- 其中 $n_1 = \sum_{i=1}^n \delta_i$
- 对数似然函数为:

$$\ell(\lambda) = \ln L(\lambda) = n_1 \ln \lambda - \sum_{i=1}^n (\delta_i y_i + (1 - \delta_i) t_i) \lambda$$

$$\ell'(\lambda) = \frac{n_1}{\lambda} - \sum_{i=1}^n (\delta_i y_i + (1 - \delta_i) t_i) = 0$$

指数分布（续）

■ MLE 为：

$$\hat{\lambda}_{\text{MLE}} = \frac{n_1}{\sum_{i=1}^n (\delta_i Y_i + (1 - \delta_i) t_i)} = \frac{n_1}{\sum_{i=1}^n \min(Y_i, t_i)} = \frac{n_1}{\sum_{i=1}^n X_i}$$

- $X_i = \min(Y_i, t_i)$
- 平均生存时间： $1/\hat{\lambda}_{\text{MLE}}$
- 至少生存 t_0 时间的概率： $\exp(-\hat{\lambda}_{\text{MLE}} t_0)$

急性骨髓性白血病生存数据分析

- 数据来自 R 中 survival 包中的数据集中'aml'
- $\lambda_{MLE} = 0.02654867$
- 平均生存时间: $1/\hat{\lambda}_{MLE} = 37.66667$





图: 左图: 黑色表示死亡, 白色表示生存, 右图: 生存概率的估计

威布尔分布

- 威布尔 (Weibull) 分布的密度为

$$f(x; \gamma, \lambda) = \lambda \gamma x^{\gamma-1} \exp(-\lambda x^\gamma) 1\{x > 0\}$$


- 其中形状参数 $\gamma > 0$, 速率参数 $\lambda > 0$
- CDF 为: $F(x) = 1 - \exp(-\lambda x^\gamma)$, $x > 0$
- 如果 $\gamma = 1$, 威布尔退化为指数分布
- 对于急性骨髓性白血病生存数据, 假设寿命服从威布尔 (Weibull) 分布, 如何估计参数 γ 和 λ ? 如何估计平均寿命? 如何估计生存概率?

高斯混合模型

- 高斯混合模型的密度为：


$$f(x) = \sum_{j=1}^J w_j \phi(x; \mu_j, \sigma_j^2)$$

- 权重 $w_j > 0$, $\sum_{j=1}^J w_j = 1$, $\phi(x; \mu, \sigma^2)$ 表示 $N(\mu, \sigma^2)$ 的密度
- 给定 $X_i \stackrel{\text{iid}}{\sim} f(x)$, 如何估计 w_j, μ_j, σ_j^2 ? (假设 J 已知)
- 考虑光谱数据, 来自 R 中 MASS 包中的数据集 'galaxies':



EM 算法求解

■ EM 算法: R 中 mclust 包提供了 Mclust 函数 (取 $J = 4$)



参数	1	2	3	4
w_j	0.0844066	0.3861555	0.3696355	0.1598024
μ_j	9.7074805	19.8044565	22.8776700	24.4351583
σ_j^2	0.1772940	0.4353339	1.2526260	34.1224385