



第七部分：非参估计

何志坚 教授/博导

华南理工大学数学学院

☎ 020-87111271

✉ hezhijian@scut.edu.cn

🌐 www.hezhijian.com.cn

2025 年 4 月 27 日

非参估计

本节考虑分布函数和密度函数的估计, 目标是通过样本的观测值构造一种函数来近似这两种函数. 本节所介绍的方法不需要知道总体的具体的分布类型, 属于非参统计方法.

- 模型假设: $X_1, \dots, X_n \stackrel{iid}{\sim} F(x)$
- 如果估计 CDF: $F(x)$?
- 如何估计 PDF: $f(x) = F'(x)$?

经验 CDF(ECDF)

设总体 X 的样本 $(X_1, \dots, X_n)$ 的一次观测值 $(x_1, \dots, x_n)$, 并将它们由小到大排列 $x_{(1)} \leq x_{(2)} \leq \dots \leq x_{(n)}$, 经验分布函数 (或称样本分布函数) 定义为

$$F_n(x) = \frac{1}{n} \sum_{i=1}^n 1\{x_i \leq x\} = \begin{cases} 0, & x < x_{(1)} \\ 1/n, & x_{(1)} \leq x < x_{(2)} \\ 2/n, & x_{(2)} \leq x < x_{(3)} \\ \vdots & \\ k/n, & x_{(k)} \leq x < x_{(k+1)} \\ \vdots & \\ 1, & x > x_{(n)} \end{cases}.$$

不难发现, 经验分布函数为右连续的阶梯函数。

用 ECDF 估计 CDF

- 固定的 x 和 n , $F_n(x)$ 表示事件 $\{X \leq x\}$ 的频率, 由强大数定律知,

$$\mathbb{P} \left(\lim_{n \rightarrow \infty} F_n(x) = F(x) \right) = 1.$$

- 格里汶科定理给出更强的结果 (几乎处处一致收敛):

$$\mathbb{P} \left(\lim_{n \rightarrow \infty} \sup_{x \in \mathbb{R}} |F_n(x) - F(x)| = 0 \right) = 1.$$

- 由此可见, 当 n 相当大时, 经验分布函数 $F_n(x)$ 是总体分布函数 $F(x)$ 的一个良好近似.

ECDF 图像




图: 经验分布函数 (黑线) 与真实的分布函数 (红线) 的对比




图: 身高数据

直方图法估计密度

- 只考虑一维连续型总体 $X \sim f(x)$. 设 $X_1, \dots, X_n$ 为样本, $R_n(a, b)$ 表示落在区间 $(a, b]$ 中的个数. 由中值定理得, 存在 $x_0 \in (a, b]$ 使得

$$f(x_0) = \frac{1}{b-a} \int_a^b f(x) dx \approx \frac{R_n(a, b)}{n(b-a)}.$$

- 设 $-\infty < t_0 < t_1 < \dots < t_m < \infty$, $t_{i+1} - t_i = h_n > 0$. 直方图法的密度估计为:

$$\hat{f}_n(x) = \begin{cases} \frac{R_n(t_i, t_{i+1})}{nh}, & x \in (t_i, t_{i+1}], i = 0, \dots, m-1 \\ 0, & x \leq t_0, x > t_m. \end{cases}$$

- 选取 t_0 为比 $X_{(1)}$ 略小的数, 选取 t_m 为比 $X_{(n)}$ 略大的数. 经验法则选取 $m \approx 1 + 3.322 \log_{10} n$.

直方图估计




图: 标准正态数据

直方图法的相合性

定理 1

如果 $f(\cdot)$ 在点 x 连续且 $\lim_n h_n = 0, \lim_n nh_n = \infty$, 则对任何 $\epsilon > 0$ 有

$$\lim_{n \rightarrow \infty} \mathbb{P}(|\hat{f}_n(x) - f(x)| \geq \epsilon) = 0.$$

如果 $f(\cdot)$ 在 $\mathbb{R}$ 上一致连续, $\int_{-\infty}^{\infty} |x|^\delta dx < \infty$ (对某个 $\delta > 0$), 且 $\lim_n h_n = 0, h_n \geq (\ln n)^2/n$, 则

$$\mathbb{P}\left(\lim_{n \rightarrow \infty} \sup_x |\hat{f}_n(x) - f(x)| = 0\right) = 1.$$

核估计法

- 考虑中心差分:

$$f(x) \approx \frac{F(x+h) - F(x-h)}{2h} \approx \frac{F_n(x+h) - F_n(x-h)}{2h}.$$

$$\hat{f}_n(x) = \frac{1}{2hn} \sum_{i=1}^n 1\{x-h < X_i \leq x+h\} = \frac{1}{hn} \sum_{i=1}^n K_0\left(\frac{x-X_i}{h}\right),$$

其中, $K_0(x) = \frac{1}{2}1\{-1 \leq x < 1\}$.

- 若函数 $K(x)$ 是 $\mathbb{R}$ 上的非负函数且满足 $\int_{-\infty}^{\infty} K(x) dx = 1$, 则称 $K(x)$ 核函数(即概率密度函数). 核估计量表示为:

$$\hat{f}_n(x) = \frac{1}{hn} \sum_{i=1}^n K\left(\frac{x-X_i}{h}\right).$$

- 常用的核函数有:

1. 均匀核函数: $K_0(x) = \frac{1}{2}1\{-1 \leq x \leq 1\}$, $K_1(x) = 1\{-1/2 \leq x \leq 1/2\}$.
2. 正态核函数: $K_2(x) = \frac{1}{\sqrt{2\pi}} e^{-x^2/2}$.

核估计的相合性

定理 2

设核函数 $K(x)$ 满足条件

$$\int_{-\infty}^{\infty} K(x)^2 dx < \infty, \quad \lim_{|x| \rightarrow \infty} |x|K(x) = 0,$$

又密度函数 f 在点 x 处连续, 且 $h_n \rightarrow 0$, $nh_n \rightarrow \infty$, 则对一切 $\epsilon > 0$, 有

$$\lim_{n \rightarrow \infty} \mathbb{P}(|\hat{f}_n(x) - f(x)| \geq \epsilon) = 0.$$

- 在满足一些正则性的条件 (如, $h_n \rightarrow 0$, $nh_n \rightarrow \infty$) 下, 可以证明直方图法的均方误差为 $O(n^{-2/3})$, 核估计的均方误差为 $O(n^{-4/5})$.
- 核估计的带宽 h_n 如何选取? 如果选择正态核函数, 经验法则: $h_n \approx 1.06S_n n^{-1/5}$.

例子

例 1

R 软件包 *dslabs* 收集了男生和女生的身高数据 (单位英寸), 由此估计男女身高总体的密度函数. 从中发现, 身高大致服从正态分布, 男生的平均身高大于女生的平均身高.




图: 核估计和直方图比较 (左图); 男女的核估计比较 (右图)