



回归分析与线性模型

何志坚 教授
华南理工大学数学学院

hezhijian@scut.edu.cn

2024 年秋季学期



目录

1 引言

2 线性回归模型

回归分析的起源

- Francis Galton (高尔顿, 1822-1911)研究父代与子代身高的关系: 身材较高的父母, 他们的孩子也较高, 但这些孩子的平均身高并没有他们的父母的平均身高高; 身材较矮的父母, 他们的孩子也较矮, 但这些孩子的平均身高却比他们的父母的平均身高高。它反映了一个规律: **孩子的身高有向他们父辈的平均身高回归的趋势。大自然具有一种约束力, 使人类身高的分布相对稳定而不产生两极分化。**
- 1855 年, 高尔顿将上述结果发表在论文《遗传的身高向平均数方向的回归》中, 这就是统计学上“回归”定义的第一次出现。
- 此后, 统计学上将研究变量 Y 与变量 X 的关系成为**回归分析 (regression analysis)**。如果两者是线性关系, 则称为“线性回归”。




Figure: 高尔顿钉板实验

回归分析的道与术

- Y : 俗称因变量（响应变量），刻画业务的核心诉求
- X : 俗称自变量（解释变量）

变量属性

- 连续型 vs. 离散型
- 数值型 vs. 分类型 (如性别, 班级)
- 无序型 vs. 有序型 (没有数值意义, 不能做代数运算, 但顺序很重要)
例如喜好程度打分, 1 表示非常不喜欢, 2 表示有点不喜欢, 3 表示一般般, 4 表示有点喜好, 5 表示非常喜欢。

回归分类

- **普通线性回归**: 因变量 Y 必须是连续型数据, 对解释性变量 X 没有太多要求。例如: $Y = \text{房价}$, $X = \{\text{区域, 朝向, 面积, 楼层, 物业}\}$
- **0-1 回归**: 因变量 Y 是 0-1 型数据。例如: $Y = \text{是否同意贷款}$, $X = \{\text{年龄, 收入, 受教育程度, 有无抵押物}\}$
- **定序回归**: 因变量 Y 是有序型数据
- **计数回归**: 因变量 Y 是计数数据
- **生存回归**: 因变量 Y 为生存数据



目录

1 引言

2 线性回归模型

普通线性回归模型

问题设定

- 模型: $y = \beta_0 + \beta_1 x_1 + \cdots + \beta_{p-1} x_{p-1} + \epsilon$ (可加性噪声)
- 代入数据: $y_i = \beta_0 + \beta_1 x_{i1} + \cdots + \beta_{p-1} x_{i,p-1} + \epsilon_i$
- 回归系数: $\beta = (\beta_0, \dots, \beta_{p-1})^\top \in \mathbb{R}^p$
- 自变量 (特征变量): $\mathbf{x}_i = (1, x_{i1}, \dots, x_{i,p-1})^\top \in \mathbb{R}^p$
- 因变量 (响应变量): $y_i = \mathbf{x}_i^\top \beta + \epsilon_i \in \mathbb{R}$
- 随机项的假设: $\epsilon_i \sim ?$


考虑以下问题

- 参数 β 的点估计
- 参数 β 的区间估计
- 系数的显著性检验: $H_0 : \beta_i = 0$ vs. $H_1 : \beta_i \neq 0$
- 预测: 给定 $\mathbf{x}$, 如何预测 y ?
- 控制: 限制 y 的范围下, 如何选择 $\mathbf{x}$?

原材料重量与成品重量数据

案例：空调制造过程中需要对某原材料进行加工，希望加工以后的成品重量不能超标。应当如何挑选原材料？

- x_i : 原材料的重量 (rough weight), y_i : 成品重量 (finished weight)
- 一元线性回归模型: $y_i = \beta_0 + \beta_1 x_i + \epsilon_i, i = 1, \dots, n = 25$



最小二乘估计 (least squares estimation, LSE)

$$\min_{\beta_0, \beta_1 \in \mathbb{R}} Q(\beta_0, \beta_1) = \sum_{i=1}^n (y_i - \beta_0 - \beta_1 x_i)^2$$


■ 平方损失函数: $Q(\beta_0, \beta_1)$

■ 最小值称为最小二乘估计量:

$$\hat{\beta}_1 = \frac{\sum_{i=1}^n (y_i - \bar{y})x_i}{\sum_{i=1}^n (x_i - \bar{x})x_i}$$

$$\hat{\beta}_0 = \bar{y} - \hat{\beta}_1 \bar{x}$$

■ 回归方程: $\hat{y} = \hat{\beta}_0 + \hat{\beta}_1 x$



$$\hat{y} = 0.308 + 0.642x$$

多元线性回归

$$y_i = \beta_0 + \beta_1 x_{i1} + \beta_2 x_{i2} + \cdots + \beta_{p-1} x_{i,p-1} + \epsilon_i, \quad i = 1, \dots, n$$

$$\begin{bmatrix} y_1 \\ y_2 \\ \vdots \\ y_n \end{bmatrix} = \begin{bmatrix} 1 & x_{11} & x_{12} & \cdots & x_{1,p-1} \\ 1 & x_{21} & x_{22} & \cdots & x_{2,p-1} \\ \vdots & \vdots & \vdots & \vdots & \vdots \\ 1 & x_{n1} & x_{n2} & \cdots & x_{n,p-1} \end{bmatrix} \begin{bmatrix} \beta_0 \\ \beta_1 \\ \vdots \\ \beta_{p-1} \end{bmatrix} + \begin{bmatrix} \epsilon_1 \\ \epsilon_2 \\ \vdots \\ \epsilon_n \end{bmatrix}$$

- 矩阵形式的模型: $\mathbf{Y} = \mathbf{X}\boldsymbol{\beta} + \boldsymbol{\epsilon}$
- 设计矩阵 (假设为固定矩阵): $\mathbf{X} \in \mathbb{R}^{n \times p}$
- 回归系数: $\boldsymbol{\beta} \in \mathbb{R}^{p \times 1}$
- 平方损失函数: $Q(\boldsymbol{\beta}) = \|\mathbf{Y} - \mathbf{X}\boldsymbol{\beta}\|_2^2 = (\mathbf{Y} - \mathbf{X}\boldsymbol{\beta})^\top (\mathbf{Y} - \mathbf{X}\boldsymbol{\beta})$
- 如何求解 LSE? 存在性以及唯一性?

LSE 存在性及唯一性

Theorem

若 $\hat{\beta}$ 达到 $Q(\beta)$ 的最小值 (即为 LSE) 当且仅当 $\hat{\beta}$ 为下述线性方程的解

$$\mathbf{X}^\top \mathbf{X} \beta = \mathbf{X}^\top \mathbf{Y}.$$

该线性方程的解必然存在, 且当 $\mathbf{X}$ 为列满秩矩阵时, 存在唯一解为

$$\hat{\beta} = (\mathbf{X}^\top \mathbf{X})^{-1} \mathbf{X}^\top \mathbf{Y}.$$

- $\mathbf{X}^\top \mathbf{X} \in \mathbb{R}^{p \times p}$: 格拉姆 (Gram) 矩阵, 是对称矩阵
- $\text{rank}(\mathbf{X}^\top \mathbf{X}) = \text{rank}(\mathbf{X})$
- $\mathbf{X}$ 为列满秩: $\text{rank}(\mathbf{X}) = p \leq n$
- 接下来仅考虑 $\text{rank}(\mathbf{X}) = p < n$ 情形
- 当 $p \gg n$ 时, 问题变为高维统计问题, 需要引入正则项处理

LSE 的无偏性及方差

Theorem

若 $\mathbb{E}[\epsilon] = \mathbf{0}$, 则 $\mathbb{E}[\hat{\beta}] = \beta$, 即 LSE 无偏。若 $\text{Var}[\epsilon] = \sigma^2 \mathbb{I}_n$, 则

$$\text{Var}[\hat{\beta}] = \sigma^2 (\mathbf{X}^\top \mathbf{X})^{-1}.$$

$$\begin{aligned}\mathbb{E}[\hat{\beta}] &= \mathbb{E}[(\mathbf{X}^\top \mathbf{X})^{-1} \mathbf{X}^\top \mathbf{Y}] = (\mathbf{X}^\top \mathbf{X})^{-1} \mathbf{X}^\top \mathbb{E}[\mathbf{Y}] \\ &= (\mathbf{X}^\top \mathbf{X})^{-1} \mathbf{X}^\top \mathbb{E}[\mathbf{X}\beta + \epsilon] \\ &= (\mathbf{X}^\top \mathbf{X})^{-1} \mathbf{X}^\top (\mathbf{X}\beta + \mathbb{E}[\epsilon])\end{aligned}$$

$$\text{Var}[\hat{\beta}] = \text{Var}[(\mathbf{X}^\top \mathbf{X})^{-1} \mathbf{X}^\top \mathbf{Y}] = (\mathbf{X}^\top \mathbf{X})^{-1} \mathbf{X}^\top \text{Var}[\mathbf{Y}] \mathbf{X} (\mathbf{X}^\top \mathbf{X})^{-1}$$

假设 A: $\mathbb{E}[\epsilon] = \mathbf{0}$, $\text{Var}[\epsilon] = \sigma^2 \mathbb{I}_n$, 简记为 $\epsilon \sim (\mathbf{0}, \sigma^2 \mathbb{I}_n)$

推论

对一元线性回归模型，设计矩阵为


$$\mathbf{X} = \begin{pmatrix} 1 & x_1 \\ 1 & x_2 \\ \vdots & \vdots \\ 1 & x_n \end{pmatrix} \quad \mathbf{X}^\top \mathbf{X} = \begin{pmatrix} n & \sum_{i=1}^n x_i \\ \sum_{i=1}^n x_i & \sum_{i=1}^n x_i^2 \end{pmatrix}$$

$$\begin{aligned} (\mathbf{X}^\top \mathbf{X})^{-1} &= \frac{1}{n \sum_{i=1}^n x_i^2 - (\sum_{i=1}^n x_i)^2} \begin{pmatrix} \sum_{i=1}^n x_i^2 & -\sum_{i=1}^n x_i \\ -\sum_{i=1}^n x_i & n \end{pmatrix} \\ &= \begin{pmatrix} \frac{1}{n} + \frac{\bar{x}^2}{\ell_{xx}} & -\bar{x}/\ell_{xx} \\ -\bar{x}/\ell_{xx} & 1/\ell_{xx} \end{pmatrix} \end{aligned}$$

- $\text{Var}(\hat{\beta}_0) = (\frac{1}{n} + \frac{\bar{x}^2}{\ell_{xx}})\sigma^2$, $\text{Var}(\hat{\beta}_1) = \frac{\sigma^2}{\ell_{xx}}$, $\ell_{xx} = \sum_{i=1}^n (x_i - \bar{x})^2$
- 方差受什么因素影响？如何估计 σ^2 ？

σ^2 的估计

- 拟合值: $\hat{Y} = X\hat{\beta} = X(X^T X)^{-1} X^T Y = PY$
- 投影矩阵: $P = X(X^T X)^{-1} X^T \in \mathbb{R}^{n \times n}$, $P = P^T$, $P^2 = P$
- 残差值: $\hat{e} = Y - \hat{Y} = (\mathbb{I}_n - P)Y$
- 残差平方和: $S_e^2 = \|\hat{e}\|_2^2 = Y^T (\mathbb{I}_n - P)Y$



σ^2 的估计

Theorem

若 $\text{rank}(\mathbf{X}) = p < n$ 以及假设 $\mathbf{A}: \boldsymbol{\epsilon} \sim (\mathbf{0}, \sigma^2 \mathbb{I}_n)$ 成立, 则有

$$\mathbb{E}[\hat{\sigma}^2] = \sigma^2, \quad \hat{\sigma}^2 = \frac{S_e^2}{n - p}.$$

Lemma (矩阵的迹的循环性质)

对任意的 $\mathbf{A} \in \mathbb{R}^{m \times n}$, $\mathbf{B} \in \mathbb{R}^{n \times m}$, 有 $\text{tr}(\mathbf{AB}) = \text{tr}(\mathbf{BA})$, 其中 $\text{tr}(\cdot)$ 表示矩阵的迹, 即对角线元素的和。

Proof.

$$\begin{aligned} \because \mathbb{E}[S_e^2] &= \mathbb{E}[\mathbf{Y}^\top (\mathbb{I}_n - \mathbf{P}) \mathbf{Y}] = \mathbb{E}[\text{tr}(\mathbf{Y}^\top (\mathbb{I}_n - \mathbf{P}) \mathbf{Y})] = \mathbb{E}[\text{tr}((\mathbb{I}_n - \mathbf{P}) \mathbf{Y} \mathbf{Y}^\top)] \\ \therefore \mathbb{E}[S_e^2] &= \text{tr}(\mathbb{E}[(\mathbb{I}_n - \mathbf{P}) \mathbf{Y} \mathbf{Y}^\top]) = \text{tr}((\mathbb{I}_n - \mathbf{P}) \mathbb{E}[\mathbf{Y} \mathbf{Y}^\top]) \\ \because \mathbb{E}[\mathbf{Y} \mathbf{Y}^\top] &= \text{Var}[\mathbf{Y}] + \mathbb{E}[\mathbf{Y}] \mathbb{E}[\mathbf{Y}^\top] = \sigma^2 \mathbb{I}_n + \mathbf{X} \boldsymbol{\beta} (\mathbf{X} \boldsymbol{\beta})^\top \\ \therefore \mathbb{E}[S_e^2] &= \text{tr}(\sigma^2 (\mathbb{I}_n - \mathbf{P}) + (\mathbb{I}_n - \mathbf{P}) \mathbf{X} \boldsymbol{\beta} (\mathbf{X} \boldsymbol{\beta})^\top) = \sigma^2 \text{tr}(\mathbb{I}_n - \mathbf{P}) = \sigma^2 (n - \text{tr}(\mathbf{P})) \\ \text{最后, } \text{tr}(\mathbf{P}) &= \text{tr}(\mathbf{X} (\mathbf{X}^\top \mathbf{X})^{-1} \mathbf{X}^\top) = \text{tr}((\mathbf{X}^\top \mathbf{X})^{-1} \mathbf{X}^\top \mathbf{X}) = \text{tr}(\mathbb{I}_p) = p \quad \square \end{aligned}$$

正态性假设以及抽样分布定理

Theorem

若 $\text{rank}(\mathbf{X}) = p < n$ 以及假设 $B: \boldsymbol{\epsilon} \sim N(\mathbf{0}, \sigma^2 \mathbb{I}_n)$ 成立, 则有

- $\hat{\boldsymbol{\beta}} \sim N(\boldsymbol{\beta}, \sigma^2 (\mathbf{X}^\top \mathbf{X})^{-1})$,
- $\frac{(n-p)\hat{\sigma}^2}{\sigma^2} = \frac{S_e^2}{\sigma^2} \sim \chi^2(n-p)$,
- $\hat{\boldsymbol{\epsilon}}$ 与 $\hat{\mathbf{Y}}$ 独立,
- S_e^2 (或 $\hat{\sigma}^2$) 与 $\hat{\boldsymbol{\beta}}$ 独立。

Corollary

在上述定理条件下, 有

$$\frac{\hat{\beta}_i - \beta_i}{\hat{\sigma} \sqrt{c_{ii}}} = \frac{\hat{\beta}_i - \beta_i}{\text{se}(\hat{\beta}_i)} \sim t(n-p),$$

其中 $(\mathbf{X}^\top \mathbf{X})^{-1} = (c_{ij})_{i,j=0,\dots,p-1}$, $\text{se}(\hat{\beta}_i) = \hat{\sigma} \sqrt{c_{ii}}$ 为 $\hat{\beta}_i$ 的标准误的估计量。

关键证明

- $\mathcal{C}(X)$ 为 X 所有列张成的 $\mathbb{R}^n$ 的线性子空间, 标准正交基设为 $\xi_1, \dots, \xi_p$
- $\mathcal{C}(X)^\perp$ 为其正交补空间, 标准正交基设为 $\xi_{p+1}, \dots, \xi_n$
- $\exists z_1, \dots, z_n$ 使得 $\hat{Y} = \sum_{i=1}^p z_i \xi_i \in \mathcal{C}(X)$, $\hat{\epsilon} = \sum_{i=p+1}^n z_i \xi_i \in \mathcal{C}(X)^\perp$
- $Y = \hat{Y} + \hat{\epsilon} = \sum_{i=1}^n z_i \xi_i = [\xi_1, \dots, \xi_n][z_1, \dots, z_n]^\top =: UZ$
- $Z = U^\top Y \sim N(\textcolor{red}{U}^\top X\beta, \sigma^2 \mathbb{I}_n) \implies z_i \overset{\text{ind}}{\sim} N(\mu_i, \sigma^2)$
- $\therefore \hat{Y} \perp \hat{\epsilon}$
- $\hat{\beta} = (X^\top X)^{-1} X^\top (\hat{Y} + \hat{\epsilon}) = (X^\top X)^{-1} X^\top \hat{Y} \perp S_e^2 = \|\hat{\epsilon}\|_2^2$
- $S_e^2 = \|\hat{\epsilon}\|_2^2 = \sum_{i=p+1}^n z_i^2$
- $\mathbb{E}[\hat{\epsilon}] = \sum_{i=p+1}^n \mathbb{E}[z_i] \xi_i = 0 \implies \mathbb{E}[z_i] = 0, i = p+1, \dots, n$
- $S_e^2/\sigma^2 = \sum_{i=p+1}^n (z_i/\sigma)^2 \sim \chi^2(n-p)$

参数的区间估计与假设检验

- 由于 σ^2 未知, β_i 的 $100(1 - \alpha)\%$ 置信区间为:

$$\hat{\beta}_i \pm t_{1-\alpha/2}(n-p)se(\hat{\beta}_i).$$

- 考虑检验问题

$$H_0 : \beta_i = \beta_i^* \text{ vs. } H_1 : \beta_i \neq \beta_i^*,$$

选择拒绝域 $W = \{|t| > t_{1-\alpha/2}(n-p)\}$, 其中检验统计量为

$$T = \frac{\hat{\beta}_i - \beta_i^*}{se(\hat{\beta}_i)} \stackrel{H_0}{\sim} t(n-p).$$

我们主要关心 $\beta_i^* = 0$ 的情形, 若 H_0 成立则说明 β_i 是不显著的。

- σ^2 的 $100(1 - \alpha)\%$ 置信区间为:

$$\left[\frac{S_e^2}{\chi_{1-\alpha/2}^2(n-p)}, \frac{S_e^2}{\chi_{\alpha/2}^2(n-p)} \right].$$

整体的显著性检验


考虑如下检验：

$$H_0 : \beta_1 = \cdots = \beta_{p-1} = 0 \text{ vs. } H_1 : \beta_{i^*} \neq 0 \exists i^* \geq 1.$$

- 总离差平方和 (SST): $S_T^2 = \sum_{i=1}^n (y_i - \bar{Y})^2 = \|\mathbf{Y} - \bar{\mathbf{Y}}\mathbf{1}_n\|_2^2$
- 回归平方和 (SSR): $S_R^2 = \sum_{i=1}^n (\hat{y}_i - \bar{Y})^2 = \|\hat{\mathbf{Y}} - \bar{\mathbf{Y}}\mathbf{1}_n\|_2^2$
- 残差平方和 (SSE): $S_e^2 = \sum_{i=1}^n (y_i - \hat{y}_i)^2 = \|\mathbf{Y} - \hat{\mathbf{Y}}\|_2^2$

三角等式：

$$S_T^2 = S_R^2 + S_e^2$$



广义似然比检验

考虑如下检验：

$$H_0 : \beta_1 = \cdots = \beta_{p-1} = 0 \text{ vs. } H_1 : \beta_{i^*} \neq 0 \exists i^* \geq 1.$$

■ 似然函数：

$$L(\boldsymbol{\beta}, \sigma^2) = (2\pi\sigma^2)^{-n/2} e^{-\frac{\|\mathbf{y} - \mathbf{X}\boldsymbol{\beta}\|^2}{2\sigma^2}}$$

■ 广义似然比：

$$\text{GLR} = \frac{\sup_{\boldsymbol{\theta} \in \Theta} L(\boldsymbol{\beta}, \sigma^2)}{\sup_{\boldsymbol{\theta} \in \Theta_0} L(\boldsymbol{\beta}, \sigma^2)} = \left(\frac{S_T^2}{S_e^2} \right)^{n/2} = \left(1 + \frac{S_R^2}{S_e^2} \right)^{n/2}$$

■ F 检验拒绝域：

$$W = \{F > F_{1-\alpha}(p-1, n-p)\}, \quad F = \frac{S_R^2/(p-1)}{S_e^2/(n-p)} \stackrel{H_0}{\sim} F(p-1, n-p)$$

证明

- 目标: $S_R^2/\sigma^2 \stackrel{H_0}{\sim} \chi^2(p-1)$, $S_e^2/\sigma^2 \sim \chi^2(n-p)$, 以及 $S_R^2 \perp\!\!\!\perp S_e^2$
- 在前面的证明中取 $\boldsymbol{\xi}_1 = \frac{1}{\sqrt{n}}\mathbf{1}_n$
- $\bar{\mathbf{Y}} = \frac{1}{n}\mathbf{1}_n^\top \mathbf{Y} = \frac{1}{n}\mathbf{1}_n^\top \mathbf{U}\mathbf{z} = z_1/\sqrt{n}$
- $S_R^2 = \|\hat{\mathbf{Y}} - \bar{\mathbf{Y}}\mathbf{1}_n\|_2^2 = \|\hat{\mathbf{Y}} - z_1\boldsymbol{\xi}_1\|_2^2 = \sum_{i=2}^p z_i^2$
- 当 H_0 成立时, $\mathbb{E}[\mathbf{z}] = \mathbf{U}^\top \mathbf{X}\boldsymbol{\beta} = \beta_0 \mathbf{U}^\top \mathbf{1}_n \implies \mathbb{E}[z_i] = 0, i = 2, \dots, n$

决定系数 R^2

■ 决定系数:

$$R^2 = \frac{S_R^2}{S_T^2} = \frac{\sum_{i=1}^n (\hat{y}_i - \bar{Y})^2}{\sum_{i=1}^n (y_i - \bar{Y})^2} = 1 - \frac{S_e^2}{S_T^2} \in [0, 1]$$

- R^2 用来衡量最小二乘拟合的强度, 可视为因变量 Y 被自变量 X 解释的比率。
- R^2 是不是越大越好? 给定数据的前提下, 比较如下两个线性回归模型:

$$M_1: y_i = \beta_0 + \beta_1 x_i + \epsilon_i \text{ vs. } M_2: y_i = \beta_0 + \beta_1 x_i + \beta_2 x_i^2 + \beta_3 x_i^3 + \epsilon_i$$

■ 调整的 R^2 :

$$\tilde{R}^2 = 1 - \frac{S_e^2/(n-p)}{S_T^2/(n-1)} = 1 - \frac{n-1}{n-p} \times \frac{S_e^2}{S_T^2} < R^2$$

■ R^2 与 F 检验统计量的关系:

$$F = \frac{S_T^2 R^2 / (p-1)}{S_T^2 (1-R^2) / (n-p)} = \frac{R^2 / (p-1)}{(1-R^2) / (n-p)}$$

一元线性回归的应用

y_i : 成品重量

x_i : 原材料重量

```
lm(formula, data, subset, weights, na.action,  
    method = "qr", model = TRUE, x = FALSE, y = FALSE, qr = TRUE,  
    singular.ok = TRUE, contrasts = NULL, offset, ...)
```

```
rod = data.frame(  
  id = seq(1:25),  
  rough_weight = c(2.745, 2.700, 2.690, 2.680, 2.675, 2.670, 2.665,  
                   2.660, 2.655, 2.655, 2.650, 2.650, 2.645, 2.635,  
                   2.630, 2.625, 2.625, 2.620, 2.615, 2.615, 2.615,  
                   2.610, 2.590, 2.590, 2.565),  
  finished_weight = c(2.080, 2.045, 2.050, 2.005, 2.035, 2.035, 2.020,  
                     2.005, 2.010, 2.000, 2.000, 2.005, 2.015, 1.990,  
                     1.990, 1.995, 1.985, 1.970, 1.985, 1.990, 1.995,  
                     1.990, 1.975, 1.995, 1.955)  
)  
lm.rod = lm(finished_weight~rough_weight,data=rod)  
summary(lm.rod)
```

Figure: 原材料重量与成品重量例子

回归结果解读

Call:

```
lm(formula = finished_weight ~ rough_weight, data = rod)
```

Residuals:

	Min	1Q	Median	3Q	Max
	-0.023558	-0.008242	0.001074	0.008179	0.024231

Coefficients:

	Estimate	Std. Error	t value	Pr(> t)
(Intercept)	0.30773	0.15608	1.972	0.0608 .
rough_weight	0.64210	0.05905	10.874	1.54e-10 ***

Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 0.01131 on 23 degrees of freedom

Multiple R-squared: 0.8372, Adjusted R-squared: 0.8301

F-statistic: 118.3 on 1 and 23 DF, p-value: 1.536e-10

预测

- 现有模型: $y_i = \beta_0 + \beta_1 x_{i1} + \beta_2 x_{i2} + \cdots + \beta_{p-1} x_{i,p-1} + \epsilon_i, i = 1, \dots, n$
- 给定一个新的自变量 $\mathbf{x}_* = (1, x_1^*, \dots, x_{p-1}^*)^\top$, 如何预测因变量 y_* :

$$y_* = \beta_0 + \beta_1 x_1^* + \cdots + \beta_{p-1} x_{p-1}^* + \epsilon_* = \mathbf{x}_*^\top \boldsymbol{\beta} + \epsilon_*.$$

- 正态性假设: $\epsilon_1, \dots, \epsilon_n, \epsilon_* \stackrel{\text{iid}}{\sim} N(0, \sigma^2)$
- 点估计:

$$\hat{y}_* = \mathbf{x}_*^\top \hat{\boldsymbol{\beta}} = \mathbf{x}_*^\top (\mathbf{X}^\top \mathbf{X})^{-1} \mathbf{X}^\top \mathbf{Y} \sim N(\mathbf{x}_*^\top \boldsymbol{\beta}, \sigma^2 \mathbf{x}_*^\top (\mathbf{X}^\top \mathbf{X})^{-1} \mathbf{x}_*)$$


- $\mathbb{E}[y_*] = \mathbf{x}_*^\top \boldsymbol{\beta}$ 的区间估计:

$$\hat{y}_* \pm t_{1-\alpha/2}(n-p) \hat{\sigma} \sqrt{\mathbf{x}_*^\top (\mathbf{X}^\top \mathbf{X})^{-1} \mathbf{x}_*}$$

- 一元线性回归:

$$\hat{y}_* \pm t_{1-\alpha/2}(n-2) \hat{\sigma} \sqrt{\frac{1}{n} + \frac{(x_1^* - \bar{x})^2}{\ell_{xx}}}$$

置信区间例子



预测区间

■ 点估计:

$$\hat{y}_* = \mathbf{x}_*^\top \hat{\boldsymbol{\beta}} \sim N(\mathbf{x}_*^\top \boldsymbol{\beta}, \sigma^2 \mathbf{x}_*^\top (\mathbf{X}^\top \mathbf{X})^{-1} \mathbf{x}_*)$$

■ $y_* - \hat{y}_* \sim N(0, \sigma^2(1 + \mathbf{x}_*^\top (\mathbf{X}^\top \mathbf{X})^{-1} \mathbf{x}_*))$

$$\frac{y_* - \hat{y}_*}{\hat{\sigma} \sqrt{1 + \mathbf{x}_*^\top (\mathbf{X}^\top \mathbf{X})^{-1} \mathbf{x}_*}} \sim t(n - p)$$


■ y_* 的预测区间:

$$\hat{y}_* \pm t_{1-\alpha/2}(n - p) \hat{\sigma} \sqrt{1 + \mathbf{x}_*^\top (\mathbf{X}^\top \mathbf{X})^{-1} \mathbf{x}_*}$$

■ 一元线性回归:

$$\hat{y}_* \pm t_{1-\alpha/2}(n - 2) \hat{\sigma} \sqrt{1 + \frac{1}{n} + \frac{(x_1^* - \bar{x})^2}{\ell_{xx}}}$$

预测区间例子



控制问题

- 欲使 $\mathbb{P}(y_* \leq y_0) \geq 1 - \alpha$, 该如何选择 $\mathbf{x}_*$?
- 例, 希望加工成品重量不超过 $y_0 = 2.05$ 的概率至少为 95%, 如何挑选原材料?

$$\mathbb{P} \left(\frac{y_* - \hat{y}_*}{\hat{\sigma} \sqrt{1 + \mathbf{x}_*^\top (\mathbf{X}^\top \mathbf{X})^{-1} \mathbf{x}_*}} \leq \frac{y_0 - \hat{y}_*}{\hat{\sigma} \sqrt{1 + \mathbf{x}_*^\top (\mathbf{X}^\top \mathbf{X})^{-1} \mathbf{x}_*}} \right) \geq 1 - \alpha$$


- 于是得到,

$$\frac{y_0 - \hat{y}_*}{\hat{\sigma} \sqrt{1 + \mathbf{x}_*^\top (\mathbf{X}^\top \mathbf{X})^{-1} \mathbf{x}_*}} \geq t_{1-\alpha}(n-p)$$

- 一元线性回归:

$$\hat{\beta}_0 + \hat{\beta}_1 x_1^* + t_{1-\alpha}(n-2) \hat{\sigma} \sqrt{1 + \frac{1}{n} + \frac{(x_1^* - \bar{x})^2}{\ell_{xx}}} \leq y_0$$

控制问题求解



多元线性回归的应用：波士顿房价数据集

市场房价的走向受到多种因素的影响，但房价的变化又常常令人捉摸不透。实际上，许多学者都根据现实数据（如房间数量、城镇人均可支配收入、人口密度等）对房价进行过合理的建模。请根据波士顿房价数据集，建立回归模型探索波士顿房价 (MEDV) 与 10 个自变量之间的关系 ($n = 506$, $p = 11$)，并适当解读回归结果。每个变量的含义如下：

变量名	含义
CRIM	城镇人均犯罪率
ZN	住宅用地所占比例
CHAS	虚拟变量
NOX	环保指数
RM	每栋住宅的房间数
DIS	距离 5 个波士顿的就业中心的加权距离
RAD	距离高速公路的便利指数
TAX	每一万美国的不动产税率
PTRATIO	城镇中的教师学生比例
LSTAT	地区中有多少房东属于低收入人群
MEDV	自住房屋房价中位数（均价）

回归结果解读

```
> data=read.csv('波士顿房价.csv')
> reg = lm(MEDV~.,data=data)
> summary(reg)
```

```
Call:
lm(formula = MEDV ~ ., data = data)
```

Residuals:

Min	1Q	Median	3Q	Max
-15.1814	-2.7625	-0.6243	1.8448	26.3920

Coefficients:

	Estimate	Std. Error	t value	Pr(> t)
(Intercept)	41.451747	4.903283	8.454	3.18e-16 ***
CRIM	-0.121665	0.032919	-3.696	0.000244 ***
ZN	0.046191	0.013673	3.378	0.000787 ***
CHAS	2.871873	0.862591	3.329	0.000935 ***
NOX	-18.262427	3.565247	-5.122	4.33e-07 ***
RM	3.672957	0.409127	8.978	< 2e-16 ***
DIS	-1.515951	0.187675	-8.078	5.08e-15 ***
RAD	0.283932	0.063945	4.440	1.11e-05 ***
TAX	-0.012292	0.003407	-3.608	0.000340 ***
PTRATIO	-0.930961	0.130423	-7.138	3.39e-12 ***
LSTAT	-0.546509	0.047442	-11.519	< 2e-16 ***

Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 4.789 on 495 degrees of freedom
 Multiple R-squared: 0.7342, Adjusted R-squared: 0.7289
 F-statistic: 136.8 on 10 and 495 DF, p-value: < 2.2e-16

LSE vs. MLE

■ LSE:

$$\min_{\beta} Q(\beta) = \|Y - X\beta\|_2^2$$

■ 在正态性假设下求 MLE:

$$\max_{\beta, \sigma^2} L(\beta) = (2\pi\sigma^2)^{-n/2} \exp \left\{ -\frac{Q(\beta)}{2\sigma^2} \right\}$$

■ 联系:

$$\hat{\beta}_{\text{MLE}} = \hat{\beta}_{\text{LSE}} = (X^T X)^{-1} X^T Y$$

■ σ^2 的 MLE:

$$\hat{\sigma}_{\text{MLE}}^2 = \frac{S_e^2}{n} \text{ vs. } \hat{\sigma}^2 = \frac{S_e^2}{n-p}$$

■ MLE 需要用到更强的假设，而 LSE 不需要任何假设。

优良性质：UMVUE 和 BLUE

■ 在假设 B: $\epsilon \sim N(0, \sigma^2 \mathbb{I}_n)$ 下, $\hat{\beta}$ 以及 $\hat{\sigma}^2$ 均为 UMVUE(证明略)

■ 在假设 A: $\epsilon \sim (0, \sigma^2 \mathbb{I}_n)$ 下, $\hat{\beta}$ 是否还存在某些优良性质?

答: 具有 BLUE (best linear unbiased estimator) 性质 (证明略)

一些说明

- 虽然我们分析的是简单的线性模型，但是可以推广到本质线性模型：

$$f(y) = \beta_0 + \beta_1 g_1(x_1, \dots, x_{p-1}) + \dots + \beta_{k-1} g_{k-1}(x_1, \dots, x_{p-1}) + \epsilon$$

- 如何验证 ϵ 的假设？需要进行回归诊断！（此部分省略）
- 如何处理参数个数 p 远大于样本量 n ？如何进行变量选择？可以使用 LASSO 方法，见 P208-215