

数理统计第五次作业答案

何志坚

2025 年 3 月 27 日

1. 假设 Y_i 是 PDF 为 $f(y; \theta)$ 且 CDF 为 $F(y; \theta)$ 的 iid 样本。但当 $Y_i > t_i$ 时, 我们只知道 $Y_i > t_i$, 并不能观察到 Y_i 的值。当 Y_i 被观察到时, 令 $\delta_i = 1$, 否则令 $\delta_i = 0$ 。似然函数为

$$L(\theta) = \prod_{i=1}^n f(y_i; \theta)^{\delta_i} (1 - F(t_i; \theta))^{1-\delta_i} = \prod_{i=1}^n f(x_i; \theta)^{\delta_i} S(x_i; \theta)^{1-\delta_i},$$

其中 $x_i = \min(y_i, t_i)$ 表示观测数据, 而 $S(t; \theta) = 1 - F(t; \theta)$ 在生存分析的背景下称生存函数。

在我们的课程中, 我们推导了指数分布的 MLE, 即 $Y_i \stackrel{iid}{\sim} \text{Exp}(\lambda)$ 。我们现在考虑一个更灵活的分布 **威布尔分布**。带形状参数 $\gamma > 0$ 和速率参数 $\lambda > 0$ 的威布尔分布的密度为

$$f(y; \gamma, \lambda) = \lambda \gamma y^{\gamma-1} \exp(-\lambda y^\gamma),$$

其中 $y > 0$ 。当 $y > 0$ 时, 其 CDF 为 $F(y; \gamma, \lambda) = 1 - \exp(-\lambda y^\gamma)$ 。特别的, 当 $\gamma = 1$ 时, 威布尔分布退化为指数分布, 因此它是更灵活的。现在假设 $Y_i \stackrel{iid}{\sim} f(y; \gamma, \lambda)$ 。请回答下列问题:

- (1). 推导出 γ 和 λ 的 MLE.
- (2). 给出 R 包 `survival` 中的急性白血病生存数据 `aml` 的估计参数。你可以使用一些数值算法, 如 Newton-Raphson 算法。数据如下, 其中 `time` 表示审查时间, `status` 表示生存状态 (1= 死亡, 0= 存活)。

```
library(survival)
```

```
## Warning: 程辑包 'survival' 是用 R 版本 4.2.3 来建造的
```

```
knitr::kable(aml[,1:2])
```

time	status
9	1
13	1
13	0
18	1
23	1
28	0

time	status
31	1
34	1
45	0
48	1
161	0
5	1
5	1
8	1
8	1
12	1
16	0
23	1
27	1
30	1
33	1
43	1
45	1

(3). 利用 (2) 的结果, 给出平均生存时间的估计并绘制作为 t 的函数的生存函数的估计图。

(4). 将 (3) 中的结果与我们在课堂上完成的指数人口的相关结果进行比较。

解: 由 $Y_i \stackrel{iid}{\sim} Weibull(\gamma, \lambda)$, 则我们有

$$\begin{aligned}
 L(\gamma, \lambda) &= \prod_{i=1}^n (\lambda \gamma y_i^{\gamma-1} \exp(-\lambda y_i^\gamma))^{\delta_i} (\exp(-\lambda t_i^\gamma))^{1-\delta_i} \\
 &= (\lambda \gamma)^{n_1} \prod_{i=1}^n y_i^{(\gamma-1)\delta_i} \exp\left[-\sum_{i=1}^n (\delta_i y_i^\gamma + (1-\delta_i) t_i^\gamma) \lambda\right] \\
 &= (\lambda \gamma)^{n_1} \prod_{i=1}^n x_i^{(\gamma-1)\delta_i} \exp\left[-\left(\sum_{i=1}^n x_i^\gamma\right) \lambda\right],
 \end{aligned}$$

其中 $n_1 = \sum_{i=1}^n \delta_i$, 而 $x_i = \min(y_i, t_i)$ 是观测数据。对数似然函数为

$$\ln L(\gamma, \lambda) = n_1 \ln \lambda + n_1 \ln \gamma + \left(\sum_{i=1}^n \delta_i \ln x_i \right) (\gamma - 1) - \left(\sum_{i=1}^n x_i^\gamma \right) \lambda.$$

对 λ 微分有

$$\frac{\partial \ln L(\gamma, \lambda)}{\partial \lambda} = \frac{n_1}{\lambda} - \sum_{i=1}^n x_i^\gamma = 0.$$

可得

$$\lambda = \frac{n_1}{\sum_{i=1}^n x_i^\gamma}.$$

而对 γ 微分有

$$\frac{\partial \ln L(\gamma, \lambda)}{\partial \gamma} = \frac{n_1}{\gamma} + \sum_{i=1}^n \delta_i \ln x_i - \left(\sum_{i=1}^n x_i^\gamma \ln x_i \right) \lambda = 0.$$

我们可以替换这里的 λ , 得

$$g(\gamma) := \frac{n_1}{\gamma} + \sum_{i=1}^n \delta_i \ln x_i - \frac{n_1 \sum_{i=1}^n x_i^\gamma \ln x_i}{\sum_{i=1}^n x_i^\gamma} = 0.$$

上述方程不能用代数方法求解, 因此需要用到数值算法。Newton-Raphson 算法是数值求解这类方程的一种方法。注意到

$$g'(\gamma) := -\frac{n_1}{\gamma^2} - n_1 \frac{\sum_{i=1}^n x_i^\gamma \sum_{i=1}^n x_i^\gamma (\ln x_i)^2 - (\sum_{i=1}^n x_i^\gamma \ln x_i)^2}{(\sum_{i=1}^n x_i^\gamma)^2}.$$

则求解 $g(\gamma) = 0$ 的 Newton-Raphson 迭代为

$$\gamma_{t+1} = \gamma_t - \frac{g(\gamma_t)}{g'(\gamma_t)}.$$

```
library(survival)
newtonRaphson <- function(time,status,gamma0,maxiter=1e4,eps=1e-9){
  gamma_old = gamma0
  n1 = sum(status) # number of dead
  for(i in 1:maxiter){
    tmp0= sum(time^gamma_old)
    tmp1 = sum(time^gamma_old*log(time))
    tmp2 = sum(time^gamma_old*log(time)^2)
    g = n1/gamma_old+sum(status*log(time))-n1*tmp1/tmp0
    dg = -n1/gamma_old^2 - n1*(tmp0*tmp2-tmp1^2)/tmp0^2
    gamma_new = gamma_old - g/dg
    lambda_new = n1/tmp0
    loglik_new = n1*log(lambda_new*gamma_new)+sum(status*log(time))*(gamma_new-1)
  }
}
```

```
-sum(time^gamma_new)*lambda_new # log-likelihood
cat('Iteration ', i, ': gamma = ',gamma_new,
', lambda = ',lambda_new, ', loglik = ',loglik_new,'\n',sep="")
if(abs(gamma_new-gamma_old)<eps){ # stopping rule
cat('total iterations: ', i,'\n',sep="")
break;
}
gamma_old = gamma_new
}
# estimated average survival time
surTime = lambda_new^(-1/gamma_new)*gamma(1+1/gamma_new)
return(list(gamma=gamma_new,lambda=lambda_new, loglik = loglik_new,surTime = surTime))
}
aml.result = newtonRaphson(aml$time,aml$status,0.01)
```

```
## Iteration 1: gamma = 0.01998562, lambda = 0.7591451, loglik = -126.7218
## Iteration 2: gamma = 0.03990862, lambda = 0.7363693, loglik = -113.7781
## Iteration 3: gamma = 0.07952623, lambda = 0.6928146, loglik = -100.3895
## Iteration 4: gamma = 0.157572, lambda = 0.6132365, loglik = -86.18946
## Iteration 5: gamma = 0.3068602, lambda = 0.4807591, loglik = -70.75361
## Iteration 6: gamma = 0.5656189, lambda = 0.2984165, loglik = -54.77632
## Iteration 7: gamma = 0.8920822, lambda = 0.1259354, loglik = -45.00393
## Iteration 8: gamma = 1.073908, lambda = 0.03960325, loglik = -52.96451
## Iteration 9: gamma = 1.096372, lambda = 0.02008412, loglik = -63.63687
## Iteration 10: gamma = 1.096609, lambda = 0.01843541, loglik = -65.16236
## Iteration 11: gamma = 1.096609, lambda = 0.01841872, loglik = -65.17867
## Iteration 12: gamma = 1.096609, lambda = 0.01841872, loglik = -65.17867
## total iterations: 12
```

平均生存时间为 $\mathcal{T} = g(\gamma, \lambda) = \lambda^{-1/\gamma}\Gamma(1 + 1/\gamma)$, 可被估计为


$$\hat{\mathcal{T}}_{MLE} = g(\hat{\gamma}_{MLE}, \hat{\lambda}_{MLE}) = \hat{\lambda}_{MLE}^{-1/\hat{\gamma}_{MLE}}\Gamma(1 + 1/\hat{\gamma}_{MLE}).$$

利用 MLE, 对于 Weibull 模型, 我们得到如下结果。

Dataset	$\hat{\gamma}_{MLE}$	$\hat{\lambda}_{MLE}$	$\hat{\mathcal{T}}_{MLE}$
aml	1.0966091	0.0184187	36.8845888

```
surFun.weibull.aml <- function(x){
return(exp(-aml.result$lambda *x^aml.result$gamma))
}
lambda.aml = sum(aml$status)/sum(aml$time)
surFun.exponential.aml <- function(x){
return(exp(-lambda.aml*x))
}
curve(surFun.weibull.aml,0,2*max(aml$time),xlab = 't',ylab = 'S(t)',
```

```
main='survival functions for aml')
curve(surFun.exponential.aml,0,2*max(aml$time), col='red', lty = 2, add = TRUE)
legend(max(aml$time),1,legend = c('Weibull model','Exponential model'),lty=c(1,2),
col = c('black','red'))
```



上图给出了威布尔模型和指数模型的估计生存函数。正如我们所看到的，对于 `aml` 数据集而言，两者的差异很小。

其他解决方案：你也可以应用牛顿-拉夫森算法同时求解两个方程，而不是在这里求解单个方程 $g(\gamma) = 0$ 。对于这种情况，你可能需要获得 Hessian 矩阵，它会更加复杂。

2. $X_1, \dots, X_n$ 是参数为 λ 的泊松分布的 iid 样本。下列哪些是 λ 的无偏估计？（ABC）

A. $\bar{X}$

B. S_n^{*2}

C. $(\bar{X} + S_n^{*2})/2$

D. S_n^2

3. $X_1, \dots, X_n$ 是 $N(\mu, \sigma^2)$ 的 iid 样本，其中 μ, σ 是未知的参数。设 $T_k =$

$k \sum_{i=1}^n (X_i - \bar{X})^2$ 是 σ^2 的一个估计量。特别地, 当 $k = 1/n$ 时, $T_k = S_n^2$, 而当 $k = 1/(n-1)$ 时, $T_k = S_n^{*2}$. 求 k 的值使得 T_k 在 MSE 的意义下最有效。

解: 由 $T_k/(k\sigma^2) \sim \chi^2(n-1)$, 我们有 $E[T_k] = k(n-1)\sigma^2$, $Var[T_k] = 2k^2(n-1)\sigma^4$. 则

$$MSE(T_k) = (E[T_k] - \sigma^2)^2 + Var[T_k] = [(n^2 - 1)k^2 - 2(n-1)k + 1]\sigma^4.$$

易见, 当 $k = 1/(n+1)$ 时, $MSE(T_k)$ 最小。

4. $X_1, \dots, X_n$ 是来自总体 X 的简单随机样本。记 $\mu_k = E[(X - E[X])^k]$. 求证

$$Var[S_n^{*2}] = \frac{\mu_4}{n} - \frac{(n-3)\mu_2^2}{n(n-1)}.$$

解: 令 $Y_i = X_i - E[X_i]$ 和 $Y = X - E[X]$. 则 $S_n^{*2} = \frac{1}{n-1} \sum_{i=1}^n (X_i - \bar{X})^2 = \frac{1}{n-1} \sum_{i=1}^n (Y_i - \bar{Y})^2 = \frac{1}{n-1} (\sum_{i=1}^n Y_i^2 - n\bar{Y}^2)$. 注意到

$$\begin{aligned} E[(S_n^{*2})^2] &= \frac{1}{(n-1)^2} E\left[\left(\sum_{i=1}^n Y_i^2 - n\bar{Y}^2\right)^2\right] \\ &= \frac{1}{(n-1)^2} \left[E\left[\left(\sum_{i=1}^n Y_i^2\right)^2\right] + n^2 E[\bar{Y}^4] - 2n E[\bar{Y}^2 \sum_{i=1}^n Y_i^2] \right]. \end{aligned}$$

此外

$$E\left[\left(\sum_{i=1}^n Y_i^2\right)^2\right] = nE[Y^4] + \sum_{i \neq j} E[Y_i^2 Y_j^2] = n\mu_4 + n(n-1)\mu_2^2,$$

$$\begin{aligned} E[\bar{Y}^4] &= n^{-4} E\left[\left(\sum_{i=1}^n Y_i\right)^4\right] = n^{-4} \left(\sum_{i=1}^n E[Y_i^4] + 6 \sum_{i < j} E[Y_i^2 Y_j^2] \right) \\ &= n^{-4} (n\mu_4 + 3n(n-1)\mu_2^2), \end{aligned}$$

$$\begin{aligned} E[\bar{Y}^2 \sum_{i=1}^n Y_i^2] &= n^{-2} E\left[\left(\sum_{i=1}^n Y_i\right)^2 \sum_{i=1}^n Y_i^2\right] = n^{-2} E\left[\left(\sum_{i=1}^n Y_i^2\right)^2\right] \\ &= n^{-1} (\mu_4 + (n-1)\mu_2^2). \end{aligned}$$

可得

$$E[(S_n^{*2})^2] = \frac{\mu_4}{n} + \frac{n^2 - 2n + 3}{n(n-1)} \mu_2^2.$$

由 $E[S_n^{*2}] = \mu_2$, 因此 $Var[S_n^{*2}] = E[(S_n^{*2})^2] - E[S_n^{*2}]^2 = \frac{\mu_4}{n} - \frac{(n-3)\mu_2^2}{n(n-1)}$.

5. $X_1, \dots, X_n$ 是来自密度为

$$f(x; \theta) = \frac{2x}{\theta^2}, \quad 0 \leq x \leq \theta.$$

的简单随机样本。

(a) 求 θ 的最大似然估计 (MLE) $\hat{\theta}_L$ 的表达式。

(b) 求 θ 的矩方法估计 $\hat{\theta}_M$ 的表达式。

(c) 对于两个估计量 $\hat{\theta}_L$ 和 $\hat{\theta}_M$, 哪个估计量在 MSE 的意义下更有效?

解: (a) 似然函数为

$$L(\theta) = \prod_{i=1}^n f(x_i; \theta) = \frac{2^n}{\theta^{2n}} \left(\prod_{i=1}^n x_i \right) 1_{\{x_{(n)} \leq \theta\}}.$$

为了最大化 $L(\theta)$, 我们需要选择 $\theta \geq x_{(n)}$ 使得 $L(\theta) = A\theta^{-2n}$, 其中 $A = 2^n \prod_{i=1}^n x_i$ 不依赖于 θ . 因此 MLE 是 $\hat{\theta}_L = X_{(n)}$.

(b) 首先, 考虑一阶矩

$$E[X] = \int_0^\theta x f(x; \theta) dx = \int_0^\theta \frac{2x^2}{\theta^2} dx = \frac{2\theta}{3}.$$

这意味着 $\theta = 3E[X]/2$. 矩方法估计为 $\hat{\theta}_M = 3\bar{X}/2$.

(c) $X_{(n)}$ 的密度为

$$f_{X_{(n)}}(x; \theta) = nF^{n-1}(x)f(x; \theta) = n \frac{x^{2(n-1)}}{\theta^{2(n-1)}} \frac{2x}{\theta^2} = \frac{2nx^{2n-1}}{\theta^{2n}}, \quad 0 \leq x \leq \theta.$$

$X_{(n)}$ 的一阶矩和二阶矩为

$$E[X_{(n)}] = \int_0^\theta \frac{2nx^{2n}}{\theta^{2n}} dx = \frac{2n\theta}{2n+1},$$

$$E[X_{(n)}^2] = \int_0^\theta \frac{2nx^{2n+1}}{\theta^{2n}} dx = \frac{n\theta^2}{n+1}.$$

$\hat{\theta}_L$ 的 MSE 为

$$\begin{aligned} MSE(\hat{\theta}_L) &= E[(\hat{\theta}_L - \theta)^2] = E[X_{(n)}^2] - 2\theta E[X_{(n)}] + \theta^2 \\ &= \frac{n\theta^2}{n+1} - \frac{4n\theta^2}{2n+1} + \theta^2 \\ &= \frac{\theta^2}{(n+1)(2n+1)}. \end{aligned}$$

X 的二阶矩为

$$E[X^2] = \int_0^\theta \frac{2x^3}{\theta^2} dx = \frac{\theta^2}{2}.$$

$\hat{\theta}_M$ 的 MSE 为

$$\begin{aligned} MSE(\hat{\theta}_M) &= Var[\hat{\theta}_M] = \frac{9Var[X]}{4n} \\ &= \frac{9}{4n}(E[X^2] - E[X]^2) \\ &= \frac{9}{4n} \left(\frac{\theta^2}{2} - \frac{4\theta^2}{9} \right) = \frac{\theta^2}{8n}. \end{aligned}$$

显然当 $n \geq 3$ 时, $MSE(\hat{\theta}_L) < MSE(\hat{\theta}_M)$, 即 MLE 更有效, 而当 $n < 3$ 时, $\hat{\theta}_M$ 更有效。