

数理统计第十五次作业答案

何志坚

2025 年 6 月 11 日

1. 遗传变异性被认为是一个物种生存的关键因素，其思想是“多样化”的种群应该有更好的机会应对不断变化的环境。下表总结了一项研究的结果，该研究旨在通过实验来验证这一假设。两种果蝇（锯齿果蝇）——一种是杂交的（品种 A），另一种是近亲繁殖的（品种 B）——被放入密封的容器中，其中食物和空间都被限制在最低限度。每百日记录每个种群中存活的果蝇数量。


日期	天数	品种 A	品种 B
2 月 2 号	0	100	100
5 月 13 号	100	250	203
8 月 21 号	200	304	214
11 月 29 号	300	403	295
3 月 8 号	400	446	330
6 月 16 号	500	482	324

- (a) 分别绘制品种 A 和品种 B 的天数和种群大小的关系图。图形是否呈线性？如果是，请用最小二乘法计算出系数及其标准误差，并绘制两条回归线。
- (b) 设 β_1^A 和 β_1^B 分别是品种 A 和品种 B 正确的斜率（即增长率）。假设两个品种的种群大小是独立的。对于这两个品种，在 $\epsilon_i \stackrel{iid}{\sim} N(0, \sigma^2)$ 的相同假设下，我们是否有足够的证据拒绝原假设 $\beta_1^A \leq \beta_1^B$ （显著性水平 $\alpha = 0.05$ ）？或者说，这些数据是否支持这样一个理论：基因混合的群体在恶劣的环境中有更好的生存机会？（提示：仿照方差相同的两个正态总体均值差的假设检验，构造相应的 t 检验统计量）

解：

```
day = seq(0,500,by=100)
A = c(100,250,304,403,446,482)
B = c(100,203,214,295,330,324)
matplot(day,cbind(A,B),pch=1:2,ylab="population size",
ylim = c(100,550))
legend(0,550,c("Strain A", "Strain B"),pch = 1:2,
col=c("black","red"))
lm.A = lm(A~day)
```

```
lm.B = lm(B~day)
abline(coef(lm.A),lty=2)
abline(coef(lm.B),lty=2,col="red")
text(120,300,expression(hat(y)[A] == 145.3 + 0.742 * x))
text(300,200,expression(hat(y)[B] == 131.3 + 0.452 * x),
col="red")
```



```
output = rbind(summary(lm.A)$coef,summary(lm.B)$coef)
row.names(output) = c("A-Intercept","A-Slope","B-Intercept","B-Slope")
knitr::kable(output, caption = 'The coefficients and their standard errors')
```

表 2: 系数以及它们的标准差

	Estimate	Std. Error	t value	Pr(> t)
A-Intercept	145.3333	26.8668380	5.409395	0.0056567
A-Slope	0.7420	0.0887382	8.361671	0.0011186
B-Intercept	131.3333	22.7725468	5.767178	0.0044864
B-Slope	0.4520	0.0752152	6.009420	0.0038603

现在我们检验

$$H_0: \beta_1^A \leq \beta_1^B \text{ vs. } H_1: \beta_1^A > \beta_1^B.$$

注意到 $\hat{\beta}_1^A \sim N(\beta_1^A, \sigma^2/\ell_{xx})$ 和 $S_e^2/\sigma^2 \sim \chi^2(n-2)$, 其中 S_e^2 是品种 A 的平方差和。类似的, 我们有 $\hat{\beta}_1^B \sim N(\beta_1^B, \sigma^2/\ell_{xx})$ 和 $\tilde{S}_e^2/\sigma^2 \sim \chi^2(n-2)$, 其中 $\tilde{S}_e^2$ 是品种 B 的平方差和。由 A 和 B 的独立性, 我们有

$$\hat{\beta}_1^A - \hat{\beta}_1^B \sim N(\beta_1^A - \beta_1^B, 2\sigma^2/\ell_{xx}),$$

$$\frac{S_e^2 + \tilde{S}_e^2}{\sigma^2} \sim \chi^2(2n-4).$$

可得

$$\frac{\hat{\beta}_1^A - \hat{\beta}_1^B - (\beta_1^A - \beta_1^B)}{\sqrt{\frac{S_e^2 + \tilde{S}_e^2}{(n-2)\ell_{xx}}}} \sim t(2n-4).$$

因此我们选择检验统计量为

$$T = \frac{\hat{\beta}_1^A - \hat{\beta}_1^B}{\sqrt{\frac{S_e^2 + \tilde{S}_e^2}{(n-2)\ell_{xx}}}}.$$

若 $\beta_1^A = \beta_1^B$, 我们有 $T \sim t(2n-4)$ 。拒绝域为 $W = \{T > C\}$, 其中 C 满足

$$\sup_{\beta_1^A \leq \beta_1^B} P(T > C | \beta_1^A, \beta_1^B) = P(T > C | \beta_1^A = \beta_1^B) = \alpha.$$

这里我们利用了 $T \sim t(2n-4)$ 的情况下, 最大值在边界处 $\beta_1^A = \beta_1^B$ 可达的事实 (见注 1)。因此临界值 $C = t_{1-\alpha}(2n-4)$ 。检验统计量的观测值为

$$t = \frac{0.742 - 0.452}{\sqrt{\frac{5512.14 + 3960.14}{(6-2) \times 175000}}} = 2.50 > t_{0.95}(8) = 1.8595.$$

因此我们拒绝原假设, 即, 这些数据**支持**基因混合的群体在恶劣的环境中**有**更好的生存机会的理论。

注 1: 注意到若 $\beta_1^B \geq \beta_1^A$, 则

$$\begin{aligned}
 & P(T > C | \beta_1^A, \beta_1^B) \\
 &= P\left(\hat{\beta}_1^A - \hat{\beta}_1^B - (\beta_1^A - \beta_1^B) > C \sqrt{\frac{S_e^2 + \tilde{S}_e^2}{(n-2)\ell_{xx}}} + (\beta_1^B - \beta_1^A) \middle| \beta_1^A, \beta_1^B\right) \\
 &\leq P\left(\hat{\beta}_1^A - \hat{\beta}_1^B - (\beta_1^A - \beta_1^B) > C \sqrt{\frac{S_e^2 + \tilde{S}_e^2}{(n-2)\ell_{xx}}} \middle| \beta_1^A, \beta_1^B\right) \\
 &= P\left(\hat{\beta}_1^A - \hat{\beta}_1^B > C \sqrt{\frac{S_e^2 + \tilde{S}_e^2}{(n-2)\ell_{xx}}} \middle| \beta_1^A = \beta_1^B\right) \\
 &= P(T > C | \beta_1^A = \beta_1^B).
 \end{aligned}$$

注 2: 有一些同学使用命令 `t.test` 作两样本均值差的检验, 这是不对的. 因为这两个样本不是同分布的样本, 我们的问题也不是比较均值差.

2. 考虑多元线性回归模型

$$\mathbf{Y} = \mathbf{X}\beta + \epsilon,$$

其中 $\mathbf{Y} = (y_1, \dots, y_n)^\top$, $\beta = (\beta_0, \dots, \beta_{p-1})^\top$, $\mathbf{X}$ 是 $n \times p$ 设计矩阵以及 $\epsilon = (\epsilon_1, \dots, \epsilon_n)^\top$. 假设 $\text{rank}(\mathbf{X}) = p < n$, $E[\epsilon] = \mathbf{0}$, $\text{Var}[\epsilon] = \sigma^2 I_n$, $\sigma > 0$.

(a) 证明最小二乘估计的协方差矩阵是对角矩阵当且仅当 $\mathbf{X}$ 的列 $\mathbf{X}_1, \dots, \mathbf{X}_p$ 是正交的, 即对于 $i \neq j$, $\mathbf{X}_i^\top \mathbf{X}_j = 0$.

(b) 令 $\hat{y}_i$ 和 $\hat{\epsilon}_i$ 分别为拟合值和残差. 证明 $n\sigma^2 = \sum_{i=1}^n \text{Var}[\hat{y}_i] + \sum_{i=1}^n \text{Var}[\hat{\epsilon}_i]$.

(c) 进一步假设 $\epsilon \sim N(\mathbf{0}, \sigma^2 I_n)$, 且用 F 检验来处理假设

$$H_0: \beta_1 = \beta_2 = \dots = \beta_{p-1} = 0 \text{ vs. } H_1: \sum_{i=1}^{p-1} \beta_i^2 \neq 0.$$

若决定系数 $R^2 = 0.58$, $p = 5$ 和 $n = 15$, 则在显著性水平 $\alpha = 0.05$ 下, 是否拒绝零假设? ($F_{0.95}(4, 10) = 3.48$, $F_{0.95}(5, 10) = 3.33$, $t_{0.95}(10) = 1.81$)

解:

(a) 最小二乘估计为 $\hat{\beta} = (X^\top X)^{-1} X^\top Y$. 我们已经证明 $\text{Var}[\hat{\beta}] = \sigma^2 (X^\top X)^{-1}$. 若 $\text{Var}[\hat{\beta}]$ 是对角的, 则 $X^\top X$ 是对角的, 这意味着 X 的列是正交的, 反之亦然。

(b) 残差 $\hat{\epsilon} = Y - X\hat{\beta} = Y - X(X^\top X)^{-1} X^\top Y = (I_n - P)Y$, 其中 $P = X(X^\top X)^{-1} X^\top$. 则 $\text{Var}[\hat{\epsilon}] = \text{Var}[(I_n - P)Y] = (I_n - P)(\sigma^2 I_n)(I_n - P)^\top = \sigma^2 (I_n - P)$. 此外, $\text{Var}[\hat{Y}] = \text{Var}[PY] = P(\sigma^2 I_n)P^\top = \sigma^2 P$. 因此 $\text{Var}[\hat{\epsilon}] + \text{Var}[\hat{Y}] = \sigma^2 I_n$. 故 $\sum_{i=1}^n \text{Var}[\hat{y}_i] + \sum_{i=1}^n \text{Var}[\hat{\epsilon}_i] = \text{trace}(\sigma^2 I_n) = n\sigma^2$.

(c) 检验统计量为

$$\begin{aligned} F &= \frac{S_R^2/(p-1)}{S_e^2/(n-p)} = \frac{R^2/(p-1)}{(1-R^2)/(n-p)} \\ &= \frac{0.58/2}{(1-0.58)/10} = 3.45 \\ &< F_{0.95}(4, 10) = 3.48. \end{aligned}$$

故我们接受零假设。

3. 考虑简单线性模型

$$y_i = \beta_0 + \beta_1 x_i + \epsilon_i, \quad \epsilon_i \stackrel{iid}{\sim} N(0, \sigma^2).$$

使用多元线性模型中导出的 F-检验方法对假设 $H_0: \beta_1 = 0$ vs. $H_1: \beta_1 \neq 0$ 进行检验, 看 F-检验是否与之前在简单线性模型中导出的 t-检验一致。

解: F-检验统计量为

$$F = \frac{S_R^2/(p-1)}{S_e^2/(n-p)} = \frac{S_R^2}{S_e^2/(n-2)},$$

其中

$$\begin{aligned} S_R^2 &= \sum_{i=1}^n (\hat{y}_i - \bar{y})^2 = \sum_{i=1}^n (\hat{\beta}_0 - \hat{\beta}_1 x_i - \bar{y})^2 \\ &= \sum_{i=1}^n (\bar{y} - \hat{\beta}_1 \bar{x} - \hat{\beta}_1 x_i - \bar{y})^2 \\ &= \hat{\beta}_1^2 \sum_{i=1}^n (x_i - \bar{x})^2 = \hat{\beta}_1^2 \ell_{xx}. \end{aligned}$$

t-检验统计量为

$$T = \frac{\hat{\beta}_1}{\sqrt{\frac{S_e^2}{(n-2)\ell_{xx}}}}.$$

故, $T^2 = F$. 在 H_0 假设下, $F \sim F(1, n-2)$ 和 $T \sim t(n-2)$ 。F-检验的拒绝域为 $W_1 = \{F > F_{1-\alpha}(1, n-2)\}$, t-检验的拒绝域为 $W_2 = \{|T| > t_{1-\alpha/2}(n-2)\}$. 注意到 $P(|T| > t_{1-\alpha/2}(n-2)|H_0) = P(T^2 > t_{1-\alpha/2}^2(n-2)^2|H_0) = 1 - \alpha$. 因为在 H_0 假设下, $T^2 \sim F(1, n-2)$, 我们有 $t_{1-\alpha/2}^2(n-2)^2 = F_{1-\alpha}(1, n-2)$. 这意味这 $W_1 = W_2$, 即两个检验实际上是一样的。

4. 市场房价的走向受到多种因素的影响, 但房价的变化又常常令人捉摸不透。实际上, 许多学者都根据现实数据(如房间数量、城镇人均可支配收入、人口密度等)对房价进行过合理的建模。请根据波士顿房价数据集, 建立回归模型探索波士顿房价 (MEDV) 与 10 个自变量之间的关系, 并适当解读回归结果。每个变量的含义如下:

变量名	含义
CRIM	城镇人均犯罪率
ZN	住宅用地所占比例
CHAS	虚拟变量
NOX	环保指数
RM	每栋住宅的房间数
DIS	距离 5 个波士顿的就业中心的加权距离
RAD	距离高速公路的便利指数
TAX	每一万美国的不动产税率
PTRATIO	城镇中的教师学生比例
LSTAT	地区中有多少房东属于低收入人群
MEDV	自住房屋房价中位数 (均价)

如果使用 R, 下面这种方式可以加载该数据集。下面展示前 6 组数据 (不是完整数据)。

```
# 下载数据文件放在工作目录里面（用‘getwd()’来获取当前工作目录）
# 否则要用绝对路径
data=read.csv('波士顿房价.csv')
knitr::kable(head(data),caption = '波士顿房价数据集前六行')
```

表 4: 波士顿房价数据集前六行

CRIM	ZN	CHAS	NOX	RM	DIS	RAD	TAX	PTRATIO	LSTAT	MEDV
0.00632	18	0	0.538	6.575	4.0900	1	296	15.3	4.98	24.0
0.02731	0	0	0.469	6.421	4.9671	2	242	17.8	9.14	21.6
0.02729	0	0	0.469	7.185	4.9671	2	242	17.8	4.03	34.7
0.03237	0	0	0.458	6.998	6.0622	3	222	18.7	2.94	33.4
0.06905	0	0	0.458	7.147	6.0622	3	222	18.7	5.33	36.2
0.02985	0	0	0.458	6.430	6.0622	3	222	18.7	5.21	28.7

解:

```
data=read.csv('波士顿房价.csv')
summary(data)
```

```
##          CRIM              ZN              CHAS              NOX
##  Min.   : 0.00632   Min.    : 0.00   Min.    :0.00000   Min.    :0.3850
## 1st Qu.: 0.08205   1st Qu.: 0.00   1st Qu.:0.00000   1st Qu.:0.4490
## Median : 0.25651   Median : 0.00   Median :0.00000   Median :0.5380
## Mean   : 3.61352   Mean    :11.36   Mean    :0.06917   Mean    :0.5547
## 3rd Qu.: 3.67708   3rd Qu.:12.50   3rd Qu.:0.00000   3rd Qu.:0.6240
## Max.   :88.97620   Max.    :100.00   Max.    :1.00000   Max.    :0.8710
##          RM              DIS              RAD              TAX
##  Min.   :3.561   Min.    : 1.130   Min.    : 1.000   Min.    :187.0
## 1st Qu.:5.886   1st Qu.: 2.100   1st Qu.: 4.000   1st Qu.:279.0
## Median :6.208   Median : 3.207   Median : 5.000   Median :330.0
## Mean   :6.285   Mean    : 3.795   Mean    : 9.549   Mean    :408.2
## 3rd Qu.:6.623   3rd Qu.: 5.188   3rd Qu.:24.000   3rd Qu.:666.0
## Max.   :8.780   Max.    :12.127   Max.    :24.000   Max.    :711.0
##          PTRATIO          LSTAT          MEDV
##  Min.    :12.60   Min.    : 1.73   Min.    : 5.00
## 1st Qu.:17.40   1st Qu.: 6.95   1st Qu.:17.02
## Median :19.05   Median :11.36   Median :21.20
```

```
## Mean :18.46 Mean :12.65 Mean :22.53
## 3rd Qu.:20.20 3rd Qu.:16.95 3rd Qu.:25.00
## Max. :22.00 Max. :37.97 Max. :50.00
```

```
reg = lm(MEDV~.,data=data)
summary(reg)
```

```
##
## Call:
## lm(formula = MEDV ~ ., data = data)
##
## Residuals:
##      Min       1Q   Median       3Q      Max
## -15.1814  -2.7625  -0.6243   1.8448  26.3920
##
## Coefficients:
##              Estimate Std. Error t value Pr(>|t|)
## (Intercept)  41.451747   4.903283   8.454 3.18e-16 ***
## CRIM         -0.121665   0.032919  -3.696 0.000244 ***
## ZN           0.046191   0.013673   3.378 0.000787 ***
## CHAS         2.871873   0.862591   3.329 0.000935 ***
## NOX        -18.262427   3.565247  -5.122 4.33e-07 ***
## RM           3.672957   0.409127   8.978 < 2e-16 ***
## DIS         -1.515951   0.187675  -8.078 5.08e-15 ***
## RAD          0.283932   0.063945   4.440 1.11e-05 ***
## TAX         -0.012292   0.003407  -3.608 0.000340 ***
## PTRATIO     -0.930961   0.130423  -7.138 3.39e-12 ***
## LSTAT       -0.546509   0.047442 -11.519 < 2e-16 ***
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## Residual standard error: 4.789 on 495 degrees of freedom
## Multiple R-squared:  0.7342, Adjusted R-squared:  0.7289
## F-statistic: 136.8 on 10 and 495 DF, p-value: < 2.2e-16
```

```
knitr::kable(reg$coefficients)
```

	x
(Intercept)	41.4517475
CRIM	-0.1216649

	x
ZN	0.0461912
CHAS	2.8718726
NOX	-18.2624266
RM	3.6729575
DIS	-1.5159511
RAD	0.2839323
TAX	-0.0122915
PTRATIO	-0.9309614
LSTAT	-0.5465092

从回归结果中得知，房价与指标 CRIM, NOX, DIS, TAX, PTRATIO, LSTAT 负相关，与其他指标正相关。